

硕士学位论文

(专业学位硕士)

基于 LLM 与深度学习的医疗器械专利自动分类 研究与应用

Research and application of medical device patent
automatic classification based on LLM and deep learning

学生姓名 _____

指导教师 _____

学科专业 生物与医药

毕业时间 二零二六年六月

基于 LLM 与深度学习的医疗器械专利自动分类研究与应用

学位授予单位：沈阳药科大学

代码：10163

研究生姓名：

所学专业：生物与医药

学位类别：硕士

指导教师： 职称：

评阅人： 职称：

学位论文完成日期：2026 年 5 月

答辩委员会主席：

答辩时间：2026 年 6 月 x 日

计：学位论文 页

 表格 个

 插图 幅

基于 LLM 与深度学习的医疗器械专利自动分类研究与应用

研究生姓名：

导 师 姓 名：

答辩委员会主席：

答辩委员会委员：

申请学位级别：硕士学位 专业名称：生物与医药

答辩日期：

关于学位论文独立完成和内容创新的声明

本人郑重声明： 所呈交的学位论文是本人在导师的指导下进行的研究工作及所取得的成果。论文中除已注明引用和致谢的内容外，不包含其他个人已经发表或撰写过的研究成果，也不包含为获得任何教育机构的学位或证书而使用过的材料，对论文研究做出贡献的个人或集体，均在论文中作了明确声明并表示了谢意。本声明的法律责任由本人承担。

学位论文作者签名：_____ 日 期 ： _____

学位论文版权使用授权书

论文《基于 LLM 与深度学习的医疗器械专利自动分类研究与应用》系 医疗器械 学院 生物与医药 专业 _____ 在沈阳药科大学攻读博士 ☐ / 硕士 ☒ 学位期间完成的作品。

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或机构送交论文的印刷件和电子版，允许论文被查阅和借阅。本人授权沈阳药科大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等其他复制手段保存和汇编本学位论文。

（涉密、内部论文在解密后适用本授权书）

本学位论文属于

1、内部论文（ ☒ ）（期限 10 年；注：不公开年限不超过年）

2、公开论文（ ☐ ）

（请在以上相应方框内打“√”）

学位论文作者签名： _____ 年 月 日

导师签名： _____ 年 月 日

目录

摘要	I
ABSTRACT	II
第一章 绪论	1
1.1 研究背景及意义	1
1.1.1 研究背景	1
1.1.2 研究意义	3
1.2 研究现状	4
1.2.1 文本分类算法的发展	4
1.2.2 垂直领域专用预训练模型的发展	5
1.2.3 层次化文本分类技术的发展	5
1.2.4 大语言模型与自动化数据治理进展	6
1.2.5 现有研究分析	6
1.3 研究内容及流程	7
1.3.1 研究内容	8
1.3.2 研究流程	9
1.4 论文结构	10
第二章 医疗器械专利分类模型相关理论基础	11
2.1 专利数据特征与医疗器械监管体系结构	11
2.1.1 专利数据	11
2.1.2 专利分类体系	12
2.1.3 医疗器械监管分类体系	13
2.1.4 跨体系语义映射问题定义与分析	14
2.2 自动标注数据质量控制方法	15
2.2.1 一致性筛选与标签错误检测	15
2.2.2 统计等价性检验	16
2.3 语义表征与分类模型	16

2.3.1 传统机器学习模型	16
2.3.2 基于深度学习与预训练模型的语义表征	18
2.4 大语言模型与知识增强技术	21
2.4.1 基于 Qwen 的数据标注推理	21
2.4.2 RAG 检索增强	22
2.4.3 基于 Dify 的标注工程化	23
2.5 层次文本分类模型	23
2.5.1 HiTIN 模型	24
2.5.2 HGCLR 模型	24
第三章 数据集与预处理	25
3.1 数据集介绍	25
3.2 专家标注数据集构建	29
3.2.1 二级标签获取	29
3.2.2 抽样设计	31
3.2.3 抽样结果评估	33
3.3 自动标注 workflow 构建	37
3.3.1 环境搭建	37
3.3.2 自动标注 workflow 设计	38
3.3.3 自动标注结果评估	40
3.3.4 案例分析	43
3.4 置信度过滤与最终数据集	44
3.5 数据增强	45
第四章 分类模型设计与评估	47
4.1 分类模型设计	47
4.1.1 机器学习模型	47
4.1.2 深度学习模型	48
4.2 分类模型评估	51
4.2.1 模型对比实验	51

4.2.2 消融实验	55
4.2.3 外部验证	57
第五章 系统设计与实现	58
5.1 需求分析	58
5.1.1 功能需求分析	58
5.1.2 非功能性需求分析	60
5.2 系统设计	60
5.2.1 系统架构设计	60
5.2.2 数据库设计	62
5.3 系统实现	63
5.3.1 开发环境及工具	63
5.3.2 用户模块实现	64
5.3.3 单条分类模块实现	65
5.3.4 批量分类模块实现	66
5.3.5 分类历史与导出模块实现	67
5.4 系统测试与验证	67
5.4.1 功能测试	68
5.4.2 非功能测试	68
第六章 总结与展望	70
6.1 总结	70
6.2 创新点	72
6.3 展望	73
参考文献	75
致谢	80

摘要

医疗器械发明专利是医疗器械技术创新成果的重要载体。近年来，相关专利数量持续增长，但现有专利分类体系主要依据 IPC 或 CPC 等通用技术分类标准组织，难以直接对应我国《医疗器械分类目录》中的监管类别。同时，医疗器械专利文本包含医学、机械、电子、材料等多学科术语，摘要表述专业性强、类别交叉明显，给自动分类模型训练带来困难。针对上述问题，本文以主 IPC 分类号属于 A61B 的医疗器械发明专利为研究对象，开展面向《医疗器械分类目录》22 个一级产品类别的自动分类研究。

为提高训练数据质量，本文依据授权状态、附图、一级产品类别标签和文本完整性等条件筛选候选专利，并以申请号去重，获得 58495 条原始候选数据。在此基础上，构建 1104 条专家校对数据集 D2，用于评价自动标注方法和分析标签置信度。为降低原始标签噪声对训练数据构建的影响，本文基于 Qwen 大模型、Dify 工作流、《医疗器械分类目录》和《医疗器械分类规则》构建自动标注流程，在模型判断过程中引入分类目录知识、分类规则和易混类别校验机制。实验结果显示，完整标注流程在 D2 上的 Accuracy 为 0.9321，Macro F1-score 为 0.9220。随后，本文依据原始标签与自动标注标签的一致性划分高低置信层，通过 D3 抽样验证和 TOST 等价性检验确认高置信样本可用性，随后对训练中难以学习的极少数类别进行定向增强，最终形成 34493 条训练数据。

在分类模型方面，本文构建并评估 BERT-TextCNN 模型。该模型以 Chinese-RoBERTa-WWM-Ext 作为文本编码器提取上下文语义表示，并通过 TextCNN 补充局部短语和关键术语特征。实验结果显示，BERT-TextCNN 在测试集上的 Accuracy 为 0.9261，Macro F1-score 为 0.8792，Weighted F1-score 为 0.9249，整体优于 KNN、DeepPatent、PatentSBERTa、PaECTER 和 RAMHA 等对比方法。外部验证结果显示，该模型在 330 条医知桥平台 2025 年发明专利上的 Accuracy 为 0.8424，Macro F1-score 为 0.8546。基于该模型，本文开发了基于 B/S 架构的医疗器械专利自动分类系统，为医疗器械专利数据的分类管理、结果复核和后续分析提供了支撑。

关键词：医疗器械，发明专利分类，BERT，Qwen

ABSTRACT

Medical device invention patents are important carriers of technological innovation in the medical device industry. In recent years, the number of related patents has continued to increase. However, existing patent classification systems are mainly organized according to general technical standards such as IPC or CPC, and they cannot be directly matched with the regulatory categories in China's Medical Device Classification Catalogue. In addition, medical device patent texts contain terms from medicine, machinery, electronics, materials and other fields. Their abstracts are highly specialized and often involve overlapping categories, which brings difficulties to automatic classification. To address these problems, this thesis takes medical device invention patents whose main IPC classification number belongs to A61B as the research object, and studies automatic classification for the 22 first-level product categories in the Medical Device Classification Catalogue.

To improve the quality of training data, this thesis first screens candidate patents according to authorization status, drawings, first-level product category labels and text completeness, and removes duplicate records by application number. A total of 58,495 original candidate samples are obtained. On this basis, an expert-checked dataset D2 containing 1,104 samples is constructed to evaluate automatic labeling methods and analyze label confidence. For the instability of original labels, this thesis builds an automatic labeling process based on the Qwen large language model, Dify workflow, the Medical Device Classification Catalogue and the Medical Device Classification Rules. Catalogue knowledge, classification rules and verification mechanisms for easily confused categories are introduced into the model judgment process. The results show that the complete labeling process achieves an Accuracy of 0.9321 and a Macro F1-score of 0.9220 on D2. Then, high-confidence and low-confidence layers are divided according to the consistency between original labels and automatically generated labels. The availability of high-confidence samples is verified through D3 sampling validation and TOST equivalence testing. Directional data augmentation is

further conducted for the few categories that are difficult to learn during training. Finally, 34,493 training samples are formed.

In terms of classification modeling, this thesis constructs and evaluates a BERT-TextCNN model. The model uses Chinese-RoBERTa-WWM-Ext as the text encoder to extract contextual semantic representations, and uses TextCNN to supplement local phrase and key term features. The experimental results show that BERT-TextCNN achieves an Accuracy of 0.9261, a Macro F1-score of 0.8792 and a Weighted F1-score of 0.9249 on the test set, outperforming KNN, DeepPatent, PatentSBERTa, PaECTER and RAMHA as a whole. The external validation results show that the model achieves an Accuracy of 0.8424 and a Macro F1-score of 0.8546 on 330 invention patents from the Yizhiqiao platform in 2025. Based on this model, this thesis develops an automatic classification system for medical device patents using a B/S architecture, providing support for patent data classification management, result review and subsequent analysis.

Keywords: medical devices, invention patent classification, BERT, Qwen

第一章 绪论

1.1 研究背景及意义

1.1.1 研究背景

医疗器械产业是融合了生命科学、机械、电子及信息技术等多种高尖端技术于一体的高技术、高风险、高投入行业。医疗器械的技术水平直接关系到人类健康，对疾病的诊断治疗与健康维护具有至关重要的作用^[1]。在生物医学工程与人工智能技术深度融合的背景下，医疗器械已成为全球主要经济体竞相布局的关键战略领域^[2]。同时，随着我国人口老龄化的加速、慢性病发病率逐年上升，地区间医疗资源配置不平衡等问题的凸显，使医疗器械产品在疾病的预防、诊断、治疗及康复环节中体现出更加重要的作用与价值^[3]。医疗器械的创新研发已成为近年来我国健康产业领域的研究热点。

由于医疗器械产品研发周期长、资金投入巨大且面临极高的监管门槛，发明专利成为了企业保护技术成果、降低研发风险以及维持市场核心竞争力的重要手段^[4]。通过专利布局，医疗器械企业可以为高额创新研发投入构筑保护壁垒，不仅使技术创新得到了显著促进，更加速了产业的整体转型与优化升级，全球范围内，该领域的专利申请数量呈现持续增长态势。依据欧洲专利局（European Patent Office, EPO）发布的最新数据表明，2024 年度医疗器械领域的专利申请量突破 1.5 万件，在各类技术领域位居前列^[5]。在中国，依据国家药品监督管理局相关统计数据，自 2019 年以来医疗器械注册数量持续上升，反映出行业发展活跃度不断提升。这一趋势对精准的技术监测与知识产权保护机制提出了更高要求^[6]。

然而，现行的全球专利管理体系与实际的医疗器械产业监管体系之间存在严重的信息不对称。目前的专利分类主要依赖国际专利分类（International Patent Classification, IPC）^[7]和联合专利分类（Cooperative Patent Classification, CPC）^[8]系统，在 IPC 体系中，A61B 类目涉及医学影像、诊疗工具以及外科器械等范畴。但药品监管与市场准入审核通常不依赖于上述通用分类标准，而是依据各国药品监督管理部门制定的专业化分类规则开展工作。这使得国际专利分类虽然具有全

球普适性，但其分类逻辑过于广泛，与药品监督管理部门制定的《医疗器械分类目录》属于完全不同的体系。

2017 年，中国国家药品监督管理局（National Medical Products Administration, NMPA）发布新版《医疗器械分类目录》，将原有的 43 个子目整合为 22 个一级产品类别和 206 个二级产品类别^[9,10]，以适应行业发展的新需求。尽管此次改革显著优化了医疗器械管理体系的结构化水平，但专利分类系统与现行监管法规之间的体系鸿沟仍然存在。这种分类体系的脱节给医疗器械企业在创新研究过程中带来了现实困境。

在专利预警和查新阶段，企业往往难以通过通用的 IPC 分类号精准映射到医疗器械的具体监管目录类别。这导致检索结果中混杂了大量非医疗器械类或者不属于该医疗器械类别的冗余专利，严重影响查新效率与数据收集的准确性。专利分类与医疗器械分类目录映射关联的缺失，使企业和监管机构在进行技术评估时，无法快速锁定某一专利技术特征所对应的监管风险等级^[11]。这直接制约了企业在知识产权风险控制及研发方向选择上的决策效率。同时，这也为监管机构的技术评估效率带来了挑战。

如何解决这两套体系的自动映射问题一直是行业痛点。传统的人工分类方式在海量的专利文献面前，不仅效率低下，并且极易产生因标注人员的背景知识差异导致分类结果的不一致甚至错误^[12]。同时，医疗器械领域的专利文本因其独特的特性而更具挑战性：一方面表现为文档长度较长，并融合了医学、机械工程、电子学、材料科学及信息技术等多学科的专业术语；另一方面则体现在信息结构复杂，涉及跨领域的综合知识体系^[13]。

深度学习以及自然语言处理等人工智能技术的兴起，为这一瓶颈的解决带来了契机。与传统机器学习算法相比，以 BERT 为代表的自然语言处理（Natural language processing, NLP）技术可以自动提取专利摘要中的语义特征，大语言模型（Large Language Models, LLM）在长文本理解上表现出非凡的潜力^[13]。但针对医疗器械专利向专业监管的《医疗器械分类目录》自动映射这一垂直领域的研究尚属空白。

当前，实现这两套不同体系之间的自动映射主要面临着以下三个方面的技术挑战。首先，IPC 分类体系的构建基础主要是发明专利的技术原理，而《医疗器

械分类目录》的分类体系则侧重于产品的临床用途和监管风险，这两者之间的分类逻辑存在着本质的差异。这种跨体系的语义不对称，导致传统的关键词匹配或浅层语义模型难以实现两者之间的准确映射。其次，目前公开的医疗器械发明专利数据缺少依据《医疗器械分类目录》的高质量标注。这导致垂直领域模型无法提供稳定可靠的监督信号，模型可能捕获错误的技术逻辑关联，产生知识幻觉，降低了其在实际应用场景中的可靠性。此外，由于《医疗器械分类目录》的二级、三级细分子目录下样本的稀疏与极度不平衡，同时海量专利文本由行业专家人工标注时间与人力成本高昂，导致缺乏具有层级细粒度的高质量标签，制约了模型实现从通用专利向精细化层级目录转化的技术路径。如何在数据受限条件下构建稳健的第一层级映射基准，是实现全层级精细映射面临的先行挑战。

为解决该领域面临的瓶颈问题，当前亟待构建符合行业特性、面向《医疗器械分类目录》的高质量标注数据集；并在此基础上探索一种融合大模型知识推理与深度学习特征抽取的混合框架，建立医疗器械专利与行业监管标准之间的精确映射关系。

1.1.2 研究意义

发明专利是技术创新的重要体现，虽然已经形成比较完整的体系，但是主要集中在专利检索和技术领域的划分上，不能很好地满足医疗器械监管及发展对于精准匹配的需求。在医疗器械这一高度依赖专利保护且研发投入巨大的高科技领域，这种匹配缺失直接导致了研发创新与行业监管标准的脱节。而《医疗器械分类目录》是我国医疗器械产品的注册、审查、风险管理等工作的基本依据。如果能够建立起它们之间的映射关系，不仅能够消除通用专利体系与监管体系间的信息不对称，更能为企业进行知识产权精准预警以及制定研发决策提供依据，促进技术创新成果转化为实际的应用价值。同时可以支撑行业监管机构提升技术评估与注册审查的效率，从而助力国产创新医疗器械在严峻的国际市场竞争中实现高效合规与商业转化。

在专利数量持续快速增长的背景下，人工方式完成专利到监管类别的映射面临成本高、效率低和一致性低的问题。通过构建面向医疗器械分类目录的自动专利分类模型实现规模化、稳定化的专利映射或许是解决问题的关键。真实专利数

据的标签往往存在噪声，甚至是缺失，而且分类口径也随政策调整而变化，这些问题制约自动分类模型的训练效果与应用可靠性^[14]。围绕低质量原始标签条件下的专利自动分类问题开展系统研究，不仅可以填补深度学习技术在医疗器械监管映射领域的应用空白，更有助于探索数据治理与模型建模相结合的有效路径，为实现从通用技术语义向垂直监管逻辑的跨体系对齐，以及未来进一步开展层级化、精细化的专利文本深度挖掘与精细化映射提供方法参考与理论支撑。

因此，开展面向《医疗器械分类目录》的医疗器械发明专利自动分类的研究对于打通专利分类体系和行业监管标准之间的衔接，赋能医疗器械研发企业精准的创新决策与监管机构高效的技术评估，以及推动医疗器械专利领域后续的分析工作具有重要的理论意义和现实意义。

1.2 研究现状

1.2.1 文本分类算法的发展

文本分类研究经历了从基于统计学的机器学习，到基于神经网络的深度学习，到当前以预训练模型及生成式大模型为主导的演进阶段。

（1）从特征工程到预训练模型

早期的文本分类研究主要采用逻辑回归（Logistic Regression, LR）、朴素贝叶斯（Naive Bayes, NB）等模型。通过词袋模型、TF-IDF 权重向量化或 N-gram 统计特征等方法将非结构化文本映射为高维稀疏特征空间，但受限于人工特征选择的局限，无法捕获深层语义信息^[15-17]。随着深度学习的兴起与发展，2014 年，Kim 提出的 TextCNN 模型利用多尺度卷积核实现了对短语级局部语义特征自动提取^[18]。长短期记忆网络（Long Short-Term Memory, LSTM）通过门控机制解决了深层网络训练中的梯度消失问题，强化了对时序依赖关系的建模^[19]。2018 年，BERT 模型开启了“预训练+微调”的新范式，通过双向编码器表示和自注意力机制显著提升了跨领域任务的泛化性能^[20]。然而，在面对术语密集的专利长文本时，这些方法仍面临远距离特征捕获能力不足等问题。

（2）长文本分类与全局建模

针对传统模型在处理长文本时存在的瓶颈，研究者从稀疏注意力机制、层级

化编码和长上下文大模型三个技术路径实现对长文本的全局语义建模。以 Longformer 等为代表的模型通过引入稀疏注意力机制,将计算复杂度降低至线性水平,实现对长文档的直接表征^[21]。Yang 等提出的层级注意力网络 (Hierarchical Attention Networks, HAN) 首先利用编码器在词级进行分布式向量化,再通过注意力机制聚合词向量生成句子表示,再利用句子级编码器捕获句间逻辑,最终在保留局部细节的同时构建出文档级的全文表示^[22]。随着长上下文大模型技术取得突破性进展, Qwen-Long、ChatGLM-1M 等模型通过位置编码改进与外推技术,极大程度提升了对长文本全局语义关联的建模精度^[23-25]。

1.2.2 垂直领域专用预训练模型的发展

为实现对特定行业语义特征的精准对齐,预训练模型逐渐向垂直领域专用预训练模型发展。针对专利文本特有的层级结构与语义复杂性,研究界提出了多种改进模型。Lee 等提出的 PatentBERT 是在大量专利文献上进行领域适应性预训练,使它能更好地理解专业技术词汇,在 IPC 和 CPC 分类上 PatentBERT 也表现良好^[26]。Bekamiri 团队设计的 PatentSBERTa 基于 Sentence-BERT 架构,生成的句向量足以胜任基于语义相似度的多标签分类及检索任务^[27]。RoBERTa 则通过剔除 NSP 任务、引入动态掩码并扩大 Batch Size,显著增强了多标签专利分类的鲁棒性^[28]。而在处理长文本依赖方面,XLNet 凭借自回归预训练方式,性能表现甚至优于 BERT^[29]。Xie 等构建的专利专用对比学习模型则通过引入对比学习,在预训练阶段强化对硬负样本的判别能力,显著增强了模型对“有源/无源”等语义高度相似医疗器械类别的区分度^[12]。

1.2.3 层次化文本分类技术的发展

针对专利文本特有的层级结构与语义复杂性,研究界提出了多种改进模型。相较于前述方法,He Zhu 构建的层级感知树同构网络 HiTIN 更注重层级逻辑,该架构利用结构编码器将层级信息嵌入文本表示,确保模型在预测子组时能感知主组信息,从而攻克了层级分类中的逻辑一致性难题^[30]。2024 年,研究者在此基础上引入基于路径约束的交叉熵损失函数,通过在目标函数中显式惩罚违反层级包含逻辑的预测路径,强制模型遵循由大类到子类的推理链条,显著提升了模

型在数据稀疏子类上的分类精度与稳健性^[12]。这些层次化文本分类技术的发展为实现医疗器械专利文本从基础的一级分类映射向更高细粒度的二级、三级分类发展提供了理论基础。

1.2.4 大语言模型与自动化数据治理进展

2023 年，LLM 为代表的生成式 AI 开启了自然语言处理的新范式。LLM 不仅在长文档理解上展现出巨大潜力，特别是检索增强生成（Retrieval-Augmented Generation, RAG）技术的介入，允许模型引入医疗器械的领域知识作为外部依据进行决策辅助^[31]，有效缓解了垂直领域的知识过时与幻觉问题。此外，针对专家指出的高质量标注成本高、标签噪声治理困难等痛点，利用 Dify 等低代码智能体构建自动化标注 workflow，正成为实现大规模专利数据精炼与垂直领域模型深度适配的关键路径^[32]。这为本研究构建高质量训练集、解决原始标签噪声提供了系统性的技术支撑。

1.2.5 现有研究分析

（1）专利文本分类领域国内外研究进展

国内外研究者在专利文本分类领域已取得显著成果，研究热点从单一的文本特征提取逐渐向深度表征、多模态融合等方向演进。PaECTER 通过引入专利引证网络信息，实现了对专利级全局语义的增强建模，证明了非文本特征在捕捉隐含技术关联中的核心价值^[33]。Xie 等通过整合专利摘要、权利要求书及专利附图特征，利用跨模态对齐技术实现了对多源异构信息的协同表征，显著提升了识别精度^[12]。PatentSBERTa 利用增强的 SBERT 架构提升了专利间的语义距离计算精度，为处理多标签分类任务提供了稳健的向量空间支撑^[27]。针对医疗等具有高度专业壁垒的垂直领域，RAMHA 等通过在 Transformer 架构中集成适配器模块，在保留预训练模型通用语义的同时，以低参数代价完成对特定领域逻辑的精准迁移^[34]。这些成果为探索医疗器械专利向《医疗器械分类目录》的跨体系映射研究奠定了技术基础。

（2）当前存在的问题

尽管专利分类技术日益成熟，但针对《医疗器械分类目录》的医疗器械专利

自动映射研究仍属空白，并且存在以下亟待解决的技术问题：

在数据层面，存在医疗器械垂直领域自动化标注的置信度评价机制缺失。目前尚无经 NMPA 备案的标注协议支撑的公开语料库，可靠监督信号的缺失导致垂直领域模型在训练初期极易捕获错误的技术逻辑关联，进而产生知识幻觉。同时缺乏针对医疗器械垂直领域标注质量的评价标准。标注数据的缺失与自动化标注逻辑偏差严重影响模型在实际应用场景中的可靠性。因此，建立系统性的置信度评价机制，识别并剔除原始弱标签中的噪声数据，是构建稳健分类模型的前提，也是医疗器械专利垂直领域数据治理方面亟待解决的问题之一。

在模型层面，现有专利文本分类模型及预训练模型虽在通用专利分类（如 IPC、CPC 系统）任务中取得了显著成果，但直接面向医疗器械专利与《医疗器械分类目录》自动映射的专用模型仍属研究空白。目前的研究多侧重于通用技术语义的提取，忽略了医疗器械领域知识所代表的语境与专利文本的技术原理语境之间的逻辑错位。如何有效利用 RAG 等技术将医疗器械监管背景知识注入模型推理过程，从而实现跨体系的语义精准对齐，是当前模型研究所面临的新挑战。此外，模型向细粒度目录层级的精准映射也是现有模型所面临的技术难点。

在应用层面，现有的专利数据库与检索平台主要基于 IPC 或 CPC 体系构建，难以直接输出符合 NMPA 监管逻辑的分类结果，面向医疗器械垂直领域的智能化专利数据平台仍处于匮乏状态。而在实际业务中，企业与监管机构往往依赖高成本、低效率的人工检索和筛选完成不同体系下的数据映射，这不仅造成大量人力与时间成本的浪费，更容易因为标注人员专业知识的匮乏导致分类精度与一致性下降。医疗器械专利数据集成化应用工具的缺乏导致专利技术特征与监管风险等级之间存在严重的信息断层，直接制约了企业在知识产权预警、合规性查新及研发方向决策上的效率。因此，构建具备跨体系自动化映射能力的专用服务平台，是打通技术创新与行业标准之间壁垒的实际需求。

1.3 研究内容及流程

针对现有研究存在的不足，本文以主 IPC 分类号属于 A61B 的医疗器械相关发明专利为研究对象，围绕《医疗器械分类目录》一级产品类别开展自动分类研究。与 IPC 或 CPC 体系内部的专利分类不同，分类任务需要将以技术原理为主

要依据的专利文本映射到以临床用途、产品属性和监管逻辑为主要依据的医疗器械目录类别。由于两类分类体系在分类目标和判定依据上存在显著的差异，二者之间难以通过简单的规则实现直接关联。因此，本文主要围绕原始标签存在噪声、跨体系语义映射困难以及模型应用效果验证等问题展开研究。

1.3.1 研究内容

本文主要开展以下三方面研究工作：

（1）面向弱标签条件的医疗器械专利数据治理与标签质量控制

目前，在专利数据中，尚没有公开的，直接面向《医疗器械分类目录》的高质量标注语料。而完全依赖具有专业知识背景的专家进行人工校对难以覆盖大规模专利样本。为缓解这一问题，本文从智慧芽专利数据库^[35]获取主 IPC 分类号属于 A61B 的医疗器械相关发明专利数据，并依据授权状态、附图、一级产品类别标签和文本完整性等条件进行筛选与清洗。在此基础上，构建专家校对数据集，用于评价自动标注结果和分析标签质量。随后，引入 Qwen 模型、Dify 工作流、《医疗器械分类目录》和《医疗器械分类规则》构建自动标注流程，并通过原始标签与自动标注标签的一致性分析、抽样验证和 TOST 等价性检验筛选高置信训练样本，以降低噪声标签对模型训练的影响。

（2）面向跨体系映射的医疗器械专利语义表征与分类模型构建

本文研究的分类目标不是专利技术体系内部的类别细分，而是将医疗器械专利映射到《医疗器械分类目录》中的 22 个一级产品类别。由于两套体系的分类依据不同，模型难以仅依赖关键词或浅层文本相似度完成判断。针对专利摘要术语密集、类别边界交叉等特点，本文构建 BERT-TextCNN 分类模型，以 Chinese-RoBERTa-WWM-Ext 提取上下文语义表示，并通过 TextCNN 捕获局部短语、关键术语和类别判别特征。本文通过模型对比实验、消融实验和外部验证，分析模型的分类效果、结构贡献和泛化能力。

（3）面向实际分类场景的模型接入与应用验证

医疗器械专利分类在实际使用中涉及单条查询、批量处理、结果留存和结果导出等操作。为验证分类模型的应用可用性，本文设计并实现医疗器械专利自动分类原型系统。系统采用 Vue 前端、Spring Boot 后端、Flask 推理服务和 MySQL

数据库，支持单条分类、批量分类、历史查询、结果导出和类别概率可视化等功能。系统部分并非将通用 B/S 架构开发作为主要创新，而是作为模型接入和应用验证的载体，用于检验分类模型在实际专利分类流程中的使用效果，并为研究成果后续服务产业实际需求奠定基础。

1.3.2 研究流程

本文研究流程围绕数据质量控制、跨体系分类建模以及模型验证与应用三个环节展开，如图 1-1 所示。数据质量控制为模型训练提供监督信号，分类模型承担从专利技术文本到监管目录类别的映射任务，实验验证和系统应用则用于检验方法的有效性与可用性。




图 1-1 研究流程

在数据质量控制环节，以智慧芽专利数据库中的 A61B 类发明专利为候选数据来源，经过条件筛选、申请号去重和文本清洗后形成候选专利数据集。随后，通过分层抽样构建专家校对数据集 D2，并基于 Qwen 模型和 Dify^[32]平台搭建引入《医疗器械分类目录》和《医疗器械分类规则》等领域知识的自动标注 workflow。通过比较原始标签与自动标注标签的一致性，结合抽样验证和 TOST 等价性检验

筛选高置信样本，并对少数难学习类别进行定向数据增强，最终形成高置信训练数据集。

在跨体系分类建模环节，以高置信训练数据集中的专利摘要文本作为输入，构建 BERT-TextCNN 分类模型。模型先由 Chinese-RoBERTa-WWM-Ext 获得上下文语义表示，再由 TextCNN 提取局部术语特征，融合后完成《医疗器械分类目录》22 个一级产品类别的分类预测。

在模型验证与应用环节，通过模型对比实验、消融实验和外部验证评估分类模型，并将训练得到的分类模型接入原型系统，通过单条分类、批量分类、历史查询、结果导出和类别概率可视化等功能验证模型在实际分类场景中的应用效果。

1.4 论文结构

本文共分为六章，各章节安排如下：

第一章为绪论，主要介绍研究背景与意义、国内外研究现状、研究内容、研究流程和论文结构。

第二章为相关理论与技术概述，主要介绍专利数据特征与医疗器械监管体系、自动标注数据质量控制方法、语义表征方法与分类模型的演进、大语言模型与知识增强技术。

第三章为数据集与预处理，主要说明候选专利数据的筛选与清洗、专家校对数据集构建、自动标注流程、置信度过滤、案例分析和定向数据增强过程。

第四章为分类模型设计与评估，主要介绍传统机器学习模型和 BERT-TextCNN 模型的构建，并通过模型对比实验、消融实验和外部验证评估模型性能。

第五章为系统设计与实现，主要介绍医疗器械专利自动分类系统的需求分析、系统架构、数据库设计、核心功能实现以及系统测试与验证。

第六章为总结与展望，主要总结全文工作和创新点，分析当前研究不足，并提出后续研究方向。

第二章 医疗器械专利分类模型相关理论基础

本章围绕医疗器械专利自动分类任务展开相关理论与技术分析，内容包括专利文本特征与监管分类体系、弱标签数据质量控制、语义表征模型、大语言模型知识增强标注方法以及层次文本分类技术。上述内容分别对应本文研究中的跨体系映射、原始标签噪声控制、分类模型构建和后续细粒度分类扩展问题。

2.1 专利数据特征与医疗器械监管体系结构

2.1.1 专利数据

中文发明专利文本包含大量专业知识，因此具有较高的信息量并且有自身特点。其中各个组成部分对于所承载的信息量、所表达的意义以及对于分类任务的帮助程度不同，这也决定了后续如何表示该文本、如何选取相应的特征以及构建什么样的机器学习模型等。因此，了解专利文献的数据组织方式以及主要特点，是进行中文发明专利文本分类的重要基础。

一篇中文发明专利主要由以下核心要素组成：

（1）标题

即专利名称，应简洁、明确地反映该发明创造的技术领域以及主要技术特征与创新点等信息。

（2）摘要

专利文献中的摘要一般在文件开头部分出现，主要作用是概述整个文档的核心思想和主要内容。这一部分内容要明确阐述所涉及的技术领域、创新点、主要组成部分以及所要解决的问题，并对可能的应用场景或者前景进行描述。

（3）权利要求书

作为专利文献的重要组成部分，权利要求书是判断专利权保护范围的重要标准，也是有较强的法律效力以及规范化属性。权利要求书的撰写应当符合相关法律规定并具备严密的逻辑关系，是一种具有一定专业技术性和规范性的文体。

(4) 说明书

说明书是对发明内容的详细介绍，必须清楚、完整地描述发明或实用新型，以所属技术领域的技术人员能够实现为准。说明书是专利文档中篇幅最长的部分，通常包含技术领域、背景技术、发明内容、附图说明和具体实施方式五个部分。

2.1.2 专利分类体系

在医疗器械领域，由于技术的高度交叉性以及监管政策的严格性，理解不同分类体系的逻辑架构对于构建自动分类模型至关重要。

(1) 国际专利分类体系

IPC 是在 1971 年缔结的《斯特拉斯堡协定》基础上由世界知识产权组织（World Intellectual Property Organization, WIPO）制定并维护的一个分级分类体系，在全世界范围内被广泛采用的专利文献分类方法。IPC 每 5 年更新一次，从 2006 年开始核心版每年更新，高级版每 3 个月更新，以便及时反映新技术的发展变化情况^[7]。

IPC 有五个级别，分别是部（Section）、大类（Class）、小类（Subclass）、大组（MainGroup）以及小组（Subgroup）。而 IPC 分类的原则主要是以功能或者用途，也就是根据发明的技术主题来进行划分。

在 IPC 的八个部（A-H）里，只有 A 部（人类生活需要）有明确定义医疗器械的内容，在 A 部下，A61（医学或兽医学；卫生学）包含大部分与医疗有关的技术创新，而在 A61 下面又有重要分支即 A61B（诊断；外科；鉴定），它是医疗器械分类中的一个重要类别。一个具体的 IPC 示例代码如表 2-1 所示。

表 2-1 A61B1/005 IPC 代码示例

层级	代码	含义
部	A	人类生活需要
大类	A61	医学或兽医学；卫生学
小类	A61B	诊断；外科；鉴定
大组	A61B1/00	用目视或照相检查人体的腔或管的仪器，例如内窥镜...
小组	A61B1/005	可弯曲的内窥镜[2006.01]

IPC 分类的优势在于其通用性和稳定性，但其基于功能的分类逻辑有时难以直接对应医疗器械的临床监管类别。

（2）联合专利分类体系

CPC 是 EPO 与美国专利商标局（U.S. Patent and Trademark Office, USPTO）于 2013 年共同开发的一种分类体系^[8]。CPC 是在 IPC 的基础上进行大幅度扩充而形成的，目的是为了更好地进行专利检索。

尽管 CPC 在部、大类、小类层级上与 IPC 保持一致，但在小组层级上，CPC 的粒度要细得多。IPC 约有 7 万个分类条目，而 CPC 则拥有超过 25 万个分类条目，CPC 还通过 Y 部（YSection）引入了交叉技术分类，用于标记跨领域的创新。

这种高精度的分类体系使得 CPC 在捕捉技术细节方面具有显著优势，但也为分类增加了难度。

2.1.3 医疗器械监管分类体系

与 IPC、CPC 关注技术原理不同，NMPA 发布的《医疗器械分类目录》是医疗器械注册、生产、经营和使用的法定依据^[9]。

鉴于医疗器械产品的复杂性，对技术交叉或学科交叉的产品，按以下优先顺序确定归属：第一，按照临床专科优先顺序；第二，多功能产品依次按照主要功能、高风险功能、新功能优先顺序；第三，按照医疗器械管理的附件类产品，优先归属整机所在子目录或者产品类别。

为贯彻实施《医疗器械监督管理条例》和《国务院关于改革药品医疗器械审评审批制度的意见》的要求，国家食品药品监督管理总局发布的目录，目录调整工作原则上每年不少于一次^[37]。

2017 年颁布的《医疗器械分类目录》是对原有分类的一个较大调整，在这个新分类中将原来 43 类简化成 22 个一级产品类别^[38]，见表 2-2，并有三级层次划分。而这 22 种一级产品类别是中国医疗器械监管顶层架构，也是本文中所进行自动分类的任务类别。

表 2-2 《医疗器械分类目录》一级产品类别

序号	一级序号/产品类别
1	有源手术器械
2	无源手术器械
3	神经和心血管手术器械
4	骨科手术器械
5	放射治疗器械
6	医用成像器械
7	医用诊察和监护器械
8	呼吸、麻醉和急救器械
9	物理治疗器械
10	输血、透析和体外循环器械
11	医疗器械消毒灭菌器械
12	有源植入器械
13	无源植入器械
14	注输、护理和防护器械
15	患者承载器械
16	眼科器械
17	口腔科器械
18	妇产科、辅助生殖和避孕器械
19	医用康复器械
20	中医器械
21	医用软件
22	临床检验器械

2.1.4 跨体系语义映射问题定义与分析

医疗器械专利的跨体系语义映射，是从以技术原理为特征的技术发明向以临床监管为特征的管理层级进行跨域知识对齐的过程。其核心挑战在于两套体系存

在显著的逻辑断层：IPC 体系关注发明的物理实现与功能特征，而《医疗器械分类目录》则注重临床用途、专科归属以及风险等因素。因此，该映射本质上是复杂的跨域语义内在关联的深度挖掘，将泛化的技术描述精准映射至监管规则之中。

实现跨域精准映射需在数据治理、自动标注、知识增强和表征学习等多个维度协同突破，确保分类路径在多级监管目录中具备严格的逻辑一致性，从而打通从通用技术语义向垂直监管逻辑的映射路径。

2.2 自动标注数据质量控制方法

由于缺乏标准数据集，医疗器械专利数据自动化标注存在知识幻觉与标签噪声问题。为确保数据质量，本文借鉴置信学习中标签错误检测的思想，并结合一致性筛选与统计等价性检验，为构建高质量数据集提供方法支撑。

2.2.1 一致性筛选与标签错误检测

在缺少大规模专家标注数据的情况下，训练数据中的噪声标签会直接影响模型学习效果。置信学习相关研究表明，标签质量可以通过给定标签与模型预测结果之间的关系进行估计，从而识别可能存在错误的样本^[39]。同时，已有研究表明，大语言模型可用于文本标注任务，并在部分场景中取得较高的一致性和准确率^[40]。

结合本文任务，本文将原始标签与自动标注工作流输出标签视为两个来源不同的标签信号。原始标签可能受到类别边界模糊、人工判断偏差等因素影响；自动标注标签则可能受到模型理解偏差、摘要信息不足和易混类别判断错误等因素影响。二者错误来源并不完全相同，因此可通过标签一致性对样本质量进行初步判断。

当原始标签与自动标注标签一致时，样本被划为高置信候选；当二者不一致时，样本被划为低置信候选。需要说明的是，一致性筛选只能作为初步质量控制依据，不能直接证明标签一定正确，后续仍需结合抽样校对和统计检验进一步验证。

2.2.2 统计等价性检验

为了对 LLM 自动标注的弱标签数据质量进行评价，可以采用双单侧等价性检验（Two One-Sided Tests, TOST）作为数据质量检验方法^[41]。传统的统计假设检验中，研究者通常试图拒绝原假设，以证明样本间差异的显著性。然而，在数据集质量评估中，目标是证明两个分布足够接近。单纯的 p 值不显著并不能说明两者无显著差异，也就是统计学上的“无法拒绝原假设并不代表原假设成立”理论。

TOST 通过对等价性区间（Equivalence Margin, Δ ）的设定，通过判断两者差异在统计上是否落入一个可接受的微小区间内，来验证自动标注数据集与专家标注数据集在数据质量上是否具有统计学意义的等效性。其原理是通过同时执行两个方向相反的单侧假设检验，证明两组数据的指标均值差异被严格限制在预设的界限之内^[41]：

$$H_0: |\mu_1 - \mu_2| \geq \Delta \quad (2-1)$$

$$H_1: |\mu_1 - \mu_2| < \Delta \quad (2-2)$$

其中， μ_1 与 μ_2 分别代表不同标注来源的准确率基准与观测值。当且仅当两者差异的置信区间完全落在 $(-\Delta, \Delta)$ 这一等价区间内时，方可拒绝原假设 H_0 ，认定自动标注数据集在质量层面与专家标注数据集具有统计学意义上的等价性。

2.3 语义表征与分类模型

文本分类技术经历了从统计学特征到深度语义表征的演进历程。针对医疗器械专利这一垂直领域的特殊性，分析各阶段主流模型在本研究任务中的适配性与局限性，为后续模型的构建奠定理论基础。

2.3.1 传统机器学习模型

传统机器学习模型通常以 TF-IDF、N-gram 等统计特征作为输入，再通过分类器完成文本类别预测。这类方法结构清晰、训练成本较低。但在医疗器械专利分类任务中，统计特征难以表达专业术语之间的语义关系，也难以处理专利技术

描述与监管目录类别之间的跨体系对应关系。因此，传统机器学习模型仅作为与本文构建的分类模型进行性能对比的基线模型。

(1) 逻辑回归 (LR)

LR 是自然语言处理领域常用的判别式分类的基本方法^[42]。其思路是将输入特征进行加权求和之后再使用 Sigmoid 函数将其映射到(0,1)之间得到一个直观的概率预测值。尽管通过引入 L1/L2 正则可增强模型的稀疏性并抑制过拟合，但 LR 本质上仍属于线性分类器，难以捕捉专利文本中复杂的非线性语义逻辑。

(2) K 最近邻 (KNN)

KNN 是基于实例的一种懒惰学习方法，在 KNN 中相似文档在向量空间中距离较近并且具有相同的类别^[43]。虽然基于余弦相似度的距离计算更适合文本任务，但在处理高维稀疏的医疗专利数据时，维数灾难导致计算量巨大，且无法识别术语间的同义关系。

(3) 随机森林 (RF)

RF 是建立在决策树基础上的一种集成学习方法，在许多决策树基础上进行投票以减少过拟合带来的不良影响，提高模型鲁棒性^[44]。它的基本原理是 Bootstrap Aggregating，在样本以及特征选取上具有一定的随机性。RF 作为一种基于集成思想的模型虽然可以学习到复杂的非线性关系，但受限于 TF-IDF 的浅层统计特征，其无法理解医疗器械专利中极具判别性的技术上下文语义。

(4) XGBoost

XGBoost (eXtreme Gradient Boosting) 是 Gradient Boosting Decision Tree 的一个更快速、更强大的版本，被大量应用于文本分类领域^[45]，它的预测结果是每棵树预测结果求和之后再乘以相应权重。

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), f_k \in F \quad (2-3)$$

其中 F 是回归树空间。

XGBoost 支持特征级别的并行运算以及对缺失值的支持，在文本分类任务中面对大量的稀疏特征时它可以学习到更加复杂的非线性关系来弥补线性模型所不能表达的内容。与 RF 相同，XGBoost 仍然难以捕获医疗器械专利中深层的语义逻辑与技术脉络，对复杂语境表征能力的缺失，使传统机器学习算法在面对专

业领域文本语义表征时存在明显局限。

2.3.2 基于深度学习与预训练模型的语义表征

深度学习的发展，尤其是卷积神经网络和 Transformer 在自然语言处理中的应用，推动了文本分类方法的改进。这类方法能够学习文本的低维稠密表示，并捕获局部短语或上下文语义信息，为跨体系映射中的文本表征提供了基础。但分类体系差异仍需结合任务数据和领域知识进一步处理。




图 2-1 TextCNN

(1) 基于 TextCNN 的局部语义表征

TextCNN 是 Kim 于 2014 年提出的将卷积神经网络应用于文本分类的一种方法，证明了卷积对于学习短语级别的语义有效^[18]。如图 2-1 所示，它包括输入层、卷积层、池化层以及输出层。

在输入层，将长度为 n 的文本用 $n \times k$ 的词向量矩阵来表示。在卷积层使用多个不同高度 h 的卷积核，例如 $h \in \{2, 3, 4, 5, 6\}$ ，沿着词序方向移动得到不同大小的 N-gram 特征，在池化层一般使用最大池化，对于每一个特征图求最大值：

$$\hat{c} = \max \{c\} \quad (2-4)$$

这一步可以找出一个句子最突出的地方并且把变长的文本转化为定长表示，然后把每一个卷积核的最大值连接在一起作为特征向量，经过 Dropout 再送入到

Softmax 进行分类。

TextCNN 是常用的 N-gram 特征提取器，具有较好的并行性和较低的时间复杂度。在医疗器械专利文本中包含如“有源手术器械”、“超声换能器”或“血管支架”等术语，这些短语特征通常是界定分类的核心依据。TextCNN 利用多尺度卷积核可以有效提取这些具有强判别性的局部语义特征，然而，受限于卷积感受野的固定宽度，在处理复杂的长程语义时仍存在局限性。

(2) 基于预训练模型的全局语义表征

预训练模型的兴起解决了深度学习模型在处理长距离语义依赖及一词多义问题上存在的局限性。以 BERT 为代表的模型基于 Transformer 编码器结构，利用双向自注意力机制计算序列中各 Token 之间的关联权重^[20]。

如图 2-2 所示，BERT 是基于 Transformer 中 Encoder 部分，有多个自注意力层加上前向连接的 feed-forward neural network 构成，在自注意力层中，用于捕捉词与词之间联系的是自注意力机制，计算方式是如下所示：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-5)$$

其中 Q、K、V 代表表示查询、键和值向量， d_k 是向量维度。这种方法通过计算词语之间关联性以及赋予相应权重聚合信息来发现远距离依存。此外，多头注意力由于对 Q、K、V 成若干组并行计算而让网络可以同时学习到各种类型的语义联系。




图 2-2 自注意力机制

在 BERT 基础上，研究者提出了多种改进模型以进一步提升中文建模能力。本文主要使用 bert-base-chinese^[46]、chinese-roberta-wwm-ext^[47] 和 chinese-macbert-base^[48]这三个模型进行了研究，它们各自的特点如表 2-3 所示。

表 2-3 模型对比

模型	bert-base-chinese	chinese-roberta-wwm-ext	chinese-macbert-base
发布机构	Google	HFL	HFL
模型体量	12 层，768 隐藏维度	同左	同左
字表	21128，基于 BERTvocab	同左	同左
训练语料	中文 Wikipedia	中文 Wikipedia+扩展语料	中文 Wiki+CLUE 语料+新闻等通用语料
预训练策略	MLM+NSP	MLM+WWM,去除 NSP	MAC+SOP+WWM

其中，Whole Word Masking（WWM）针对中文语言特点进行了改进。在传统掩码语言模型（Masked Language Modeling, MLM）中，掩码单位通常为单个字，容易破坏完整词语的语义结构^[20, 49]。WWM 以词为最小掩码单位，对同一词中的所有字同时进行遮蔽，使模型在预测时更加依赖完整词级语义，从而提升对专业术语和固定搭配的建模能力。

MacBERT 进一步提出了 Masked Attribute Classification（MAC）任务，用语义相近的词替换被掩码位置，而非使用特殊的[MASK]符号，缩小了预训练与下游任务之间的分布差异，使模型学习到更加贴近真实语言使用场景的表示^[49]。同时，MacBERT 采用 Sentence Order Prediction（SOP）任务替代 NSP，通过判断句子顺序是否正确来建模篇章连贯性，更有利于学习长文本中的逻辑顺序关系。

（3）专利领域专用预训练模型

通用预训练模型的词表主要基于维基百科等通用语料库构建，在面对专利中的高度专业化学术语时，常出现词表外（Out-of-Vocabulary, OOV）问题。因此，研究者构建了针对专利语料的专用预训练模型，其中以 PatentBERT 与 PatentSBERTa 最具代表性。

PatentBERT 是由 Lee 等人提出的专门针对专利分类任务优化的预训练架构，通过在专利语料上重新构建词表，有效提升了模型对技术文本的表征精度^[26]。模

型在预训练阶段通过 MLM 任务学习专利特有的上下文关联,通过对大量技术权利要求书的学习,PatentBERT 能够建立起技术术语与法律效力之间的语义映射。

PatentSBERTa 由 Bekamiri 等人提出,该方法利用增强的 SBERT 生成专利文本向量,用于计算专利之间的语义距离,并进一步结合近邻方法完成 CPC 分类和语义检索任务^[27]。与直接进行类别预测的模型不同,PatentSBERTa 更强调专利文本之间的相似度建模,适合用于专利距离计算、语义检索和基于相似样本的分类场景。

PatentBERT 和 PatentSBERTa 等方法能够增强模型对专利技术语义的表示能力,但它们主要面向 IPC、CPC 等通用专利分类或专利相似度任务。本文研究对象并不是单一专利分类体系内部的类别预测,而是医疗器械专利文本与《医疗器械分类目录》之间的跨体系映射。该任务除技术原理外,还需要关注分类目录、监管规则以及“有源”、“无源”、“接触部位”等局部判别特征。因此,本文在第四章实验中引入具有代表性的专利表示与分类模型与本文构建的 BERT-TextCNN 模型进行性能对比,以检验全局语义表示与局部短语特征结合后在本文任务中的适用性。

2.4 大语言模型与知识增强技术

预训练模型可以提升专利文本的语义表征能力,但难以直接解决医疗器械垂直领域标注数据不足和人工标注成本较高的问题,LLM 与知识增强技术的兴起,为实现跨体系语义映射中的自动化标注提供了新的技术路径。

与 BERT 侧重于特征编码不同,LLM 在少量样本学习、逻辑推理以及对长文档的深度理解等方面表现出卓越的性能。通过引入 RAG,非参数化的领域知识可在生成过程中作为外部依据参与推理,从而为跨体系映射任务提供带有领域约束的标注依据。

2.4.1 基于 Qwen 的数据标注推理

Qwen 是阿里云推出的通义千问系列大模型,而 Qwen3 是该系列第三代模型,其在通用性、推理能力和对长上下文支持上都有较大改善并且在多个评估任务中

性能优异^[23]。

医疗器械专利自动分类是一个严谨的逻辑推理过程。Qwen3 通过构建思维链，能够模拟行业专家的判定路径（识别技术特征—关联临床用途—匹配分类目录），从而显著提升自动标注的逻辑一致性。由于医疗器械专利摘要中常同时包含技术结构、用途场景和产品属性等信息，自动标注过程需要模型具备较强的语义理解和规则匹配能力。Qwen3 在指令理解和推理生成方面具有较好表现，可用于辅助识别摘要中的关键技术特征，并结合分类目录知识生成初步标签。

2.4.2 RAG 检索增强

大型语言模型虽然具有很强的泛化能力，但是在专利分类等领域仍然存在幻觉以及知识过时的问题，导致结果的准确性和时效性不足。Lewis 等人在 2020 年提出的 RAG 技术为解决该问题提供了解决方案^[31]。

《医疗器械分类目录》具有高度的法定权威性并且处于常动态调整中。LLM 内部的参数化知识往往无法实时覆盖动态调整的领域知识。RAG 将非参数化的外部知识库（Knowledge Base）与参数化的生成模型结合，其工作流程如图 2-3 所示。




图 2-3 RAG 流程

RAG 通过编码器将领域知识文本转化为向量表示，在标注查询阶段为 LLM 提供外部知识依据，使模型判断能够更多参考现行分类规则和目录条目。这种方式可以在一定程度上缓解自动标注过程中的知识过时和语义漂移问题，但标注结果仍需结合专家校对和统计检验进行质量控制。

2.4.3 基于 Dify 的标注工程化

开发以大模型为基础的应用程序需要解决的问题不仅仅是模型本身的问题，在此基础上还需要考虑复杂的业务及鲁棒性等问题，因此一个中间件是必不可少的，而 Dify^[32]是一个开源 LLMOps 平台，结合了 BaaS 以及模型运维的理念，提供了从模型调用到最后部署的一整套工程化的解决方案。




图 2-4 Dify 架构图

如图 2-4 所示，基于 Dify 构建了一套具备感知、推理和修正能力的模块化的自动标注系统。其中，编排引擎负责 Qwen 等模型的封装与调用， workflow 工作室用于编排标注流程和 RAG 检索流程，部署中心则将应用以 API 形式对外提供服务。这种流程化标注方式可以提高批量标注效率，并使分类规则、目录知识和纠错条件在不同样本上保持相对一致。需要说明的是，Dify 工作流本身并不能保证标签完全正确，其输出仍需经过专家校对、一致性分析和统计检验后，才能作为模型训练数据使用。

2.5 层次文本分类模型

《医疗器械分类目录》具有较清晰的三级层级结构，层次文本分类（Hierarchical Text Classification, HTC）作为文本分类领域的前沿研究方向，利用类别间的先验隶属关系来约束并增强模型对复杂语义路径的表征能力。HTC 为实现医疗器械专利文本与分类目录三级层级之间的精细化映射提供了技术基

础。

2.5.1 HiTIN 模型

HiTIN (Hierarchy-aware Transformer with Interaction and Notification) 是 2023 年提出的一种深度融合层次结构信息的 Transformer 变体^[30]。HiTIN 引入层级交互与结构通知，解决了传统模型在处理深度层级时出现的语义稀释问题。

HiTIN 采用分层编码器，每一层不仅负责当前层级的类别预测，还通过交互模块接收来自上一层级的语义特征。基于层次感知注意力机制，通过引入层级掩码矩阵对注意力范围进行限制，从而确保模型聚焦于合理的分类路径。

HiTIN 的通知机制利用底层的预测结果反向校准高层的分布。基于双向特征传递，模型能够学习到更加严密的逻辑一致性，避免出现上一层级预测正确、下一层级预测结果矛盾的问题。

2.5.2 HGCLR 模型

利用对比学习来显式对齐文本语义与层级结构的 HGCLR (Hierarchy-Guided Contrastive Learning) 模型是一种将分类层级视为一种语义约束的层次文本分类模型。HGCLR 通过拉近同路径样本、拉远跨路径样本来增强表征的判别性^[50]。

HGCLR 采用层次约束下的对比损失函数替代传统模型中的交叉熵损失，要求文本表征与其对应的层级路径表征之间的相似度最大化。通过损失函数的约束，模型能够在高维空间中学习到符合层级拓扑结构的语义分布，有效提升了模型在处理极度相似类别时的区分能力。

尽管 HiTIN 与 HGCLR 等模型在标准的文本层次分类任务上表现优异，但在医疗器械专利跨体系语义映射中，实现 IPC 体系向监管分类体系的对齐并非单一体系内的细分任务。在一级类别尚未实现高置信度自动化标注的情况下，直接扩展到二级、三级目录分类面临着严重的样本不均衡，从而增加监督信号的噪声。因此，本文将研究范围限定在一级产品类别映射，先建立稳定的高质量标注基础和分类基准，二级、三级目录的层次化分类则作为后续研究方向展开。

第三章 数据集与预处理

专利分类模型的性能，很大程度上受制于数据本身。本章围绕医疗器械发明专利分类任务构建训练数据集，目标是得到一份覆盖《医疗器械分类目录》22个一级产品类别且质量经过校验的数据集。

本章的基本思路如下，先依据 IPC 分类表确定医疗器械专利的数据范围，并据此制定检索式；随后按授权状态、附图、标签和文本完整性进行筛选，按照申请号去重，得到包含 58495 条数据的数据集 D1。在此基础上，本文抽取 1104 条样本构建专家校对数据集 D2，用于评估不同自动标注方法，D1 中的剩余数据计为数据集 D3。根据 D2 上的评估结果，本文进一步将原始标签与工作流标签的一致性作为置信度划分依据，对未进入 D2 的样本进行高低置信分层，并通过抽样验证与 TOST 等价性检验确定高置信层的可用性。最终，本文保留 D3 中的 33327 条高置信样本，与 D2 合并形成 34431 条高质量标注数据。针对训练中无法有效学习的少数类别，本文再实施生成式数据增强，得到 62 条增强样本，第四章模型训练使用的数据总量为 34493 条。

3.1 数据集介绍

本研究的数据来源于智慧芽专利数据库^[35]。为了聚焦医疗器械发明专利，本文依据 IPC 分类表确定检索范围，图 3-1 给出了 IPC 分类表 A 部中 A61B 相关内容的节选。

基于图内分类定义，本文将主要分类号属于 A61B 的发明专利视为医疗器械产品及其相关技术的候选集合。需要说明的是，A61B 中同时包含器械和方法两类表述。在专利文本中，医疗器械产品权利要求与使用方法、控制方法或检测方法常出现在同一件申请中，方法描述通常依托具体器械完成，并未脱离医疗器械技术对象。因此，本文将 A61B 下涉及产品、装置、系统及其相关方法的专利均纳入候选范围，这样处理可以保留医疗器械技术方案的完整表达。

本文检索式设定为 APD:[* TO 20231231] AND MIPC:(A61B NOT A61B16)。其中，APD 用于限定申请日期不晚于 2023 年 12 月 31 日，MIPC 用于限定主要

IPC 分类号。检索式中排除 A61B16，是因为该组虽然属于 A61B 小类，但未出现在医疗器械分组中，和本文以医疗器械一级产品类别为目标的分类任务不一致。

A61B 诊断；外科；鉴定（分析生物材料入 G01N，如 G01N33/48）

附注

本小类包含诊断、外科和人体鉴别用的仪器、器械和方法，包括产科、切割鸡眼器械、接种疫苗器械、手指压纹、心理—身体参数测试。

小类索引

医学方法（非外科的） 1/00， 5/00， 17/00

心理—身体参数测试仪器 5/00

医疗器械

用于听诊和诊断的 5/00-10/00

用于人体的腔或管和眼睛的医学检查的 1/00， 3/00

用于口腔检查与医护的器具 1/00， 13/00

外科器械、装置或方法 17/00； 18/00

用于外科或诊断的其他仪器、器械或附件 34/00-90/00

诊断；心理—身体参数测试

图 3-1 2024 年 IPC 分类表 A 部节选

为保证数据可用性和文本完整性，本文规定数据集 D1 的筛选标准为：

（1）已授权

保留法律状态为授权的有效专利，保证技术方案的可行性及专利文本质量。

（2）有附图

保留包含说明书附图的专利，在本文以文本为主的情况下，附图为多模态扩展的基础，对后续工作有益。

（3）存在一级产品类别标签

在从智慧芽专利平台收集数据后，已经用于日常的研究。因此，部分数据存在《医疗器械分类目录》的一级产品类别标签，但存在标签质量较低的问题。

（4）文本未缺失

针对文本的分类研究，文本存在缺失时，是无法纳入的，因为它无法通过插值等手段来填充。在智慧芽专利平台中，缺失文本一般用“-”占位，本文对包含该占位符的数据进行了过滤。

完成筛选后，文本依据申请号对数据进行去重，因为申请号能够对应一件专利申请记录，按申请号去重后可避免同一专利重复进入训练集。

原始专利文本一般带有 HTML 标签、非标准的特殊字符以及标点符号等噪声信息，这会影响模型对于其语义的理解。因此，在此基础上本文对原始数据中

的摘要部分进行规范化操作。即：

（1）去除 HTML 标签

专利数据采集或者存储时往往带有网页渲染相关 HTML 标签，例如
、<p>等，这些都并非自然语言文本内容，在送入模型之前应当将其去除，否则会作为普通符号被编码，造成无效 token 比例提升，不利于模型关注到实际语义信息，在预处理阶段去除所有的 HTML 标签只保留纯文本部分。

（2）去除不可见字符

原始文本中可能包含制表符、回车符以外的控制字符。这些字符虽然眼睛看不见，但是会造成分词错误或者导致文本长度计算有误，在处理时本文尽量保留必要的换行符以便保持文章大致结构，而去除其他不可见控制字符，使得文本编码统一、可控。

（3）标点统一

因为数据来源多样化，在专利文本当中经常出现中英文标点混用的情况。同样的一个语义结构因为使用不同的标点而被当作不同的模式给模型学习造成困扰，为了降低由这种无关的形式所带来的影响，本文把所有的英文字母标点都替换成了相应的中文全角标点，使文本格式更加统一并且有利于模型更好地学习句子之间的语法关系。

（4）空格处理

在某些专利文本中，有较多连续空格或者多余的空白符，在一定程度上会使得文本过长，也会影响模型运行速度。本文对连续空格进行合并操作以缩短文本表示，在不影响文章内容的前提下删去不必要的字符，以便加快之后训练以及预测的速度。

经过上述筛选、去重和清洗后，数据集 D1 共包含 58495 条专利数据。随后通过标注与置信度过滤，最终保留 34431 条高质量标注数据，经少数类增强后，第四章用于训练的数据总量为 34493 条，各一级产品类别的最终分布如表 3-1 所示。

表 3-1 最终训练数据集一级产品类别分布

一级产品类别	样本量	增强样本量	最终样本量
医用成像器械	9732	0	9732
医用诊察和监护器械	6115	0	6115
无源手术器械	4288	0	4288
骨科手术器械	2992	0	2992
有源手术器械	2949	0	2949
眼科器械	1591	0	1591
注输、护理和防护器械	1063	0	1063
临床检验器械	1002	0	1002
医用软件	911	0	911
无源植入器械	663	0	663
神经和心血管手术器械	616	0	616
妇产科、辅助生殖和避孕器械	584	0	584
口腔科器械	308	0	308
物理治疗器械	282	0	282
中医器械	263	0	263
呼吸、麻醉和急救器械	220	0	220
医用康复器械	220	0	220
放射治疗器械	203	0	203
有源植入器械	193	0	193
患者承载器械	107	0	107
医疗器械消毒灭菌器械	98	0	98
输血、透析和体外循环器械	31	62	93
合计	34431	62	34493

3.2 专家标注数据集构建

数据集 D1 的原始标签存在质量波动，不能直接作为全量数据的最终真值。本文从 58495 条原始候选数据中抽取 1104 条样本，构建专家校对数据集 D2。D2 承担两个作用，一是作为自动标注方法的评价基准，二是作为后续置信度划分和过滤策略的统计依据。

3.2.1 二级标签获取

数据集 D1 仅有产品的第一级产品类别标签而无第二级产品类别标签，为了实现准确的二层分层抽样，在此之前需要先获得这些数据的第二级产品类标签。因此本文用《医疗器械分类目录》训练多个分类器，对数据集 D1 的摘要进行预测从而大致得到它们对应的第二级产品类标签。

本文所使用《医疗器械分类目录》来源于中国食品药品检定研究院公开数据^[38]，网站的查询接口参数为“20240618”，预计是 2024 年 6 月 18 日版本，共有 206 个二级产品类别，1701 条记录。

目录中单条数据的字段构成如表 3-2 所示。为实现语义与摘要的对齐，本文将“三级序号/产品类别”、“产品描述”和“预期用途”字段进行了拼接，格式为：“三级序号/产品类别：产品描述预期用途”。以表中数据为例，拼接后的文本为：“超声手术设备：通常由超声波发生器和带有外科尖端的手持部件组成，手持部件通常由一个换能器、一个连接构件和一个治疗头尖端组成。用于软组织的切割、止血、整形。”。

基于《医疗器械分类目录》中每个一级产品类别的数据，本文分别训练了 LR、KNN、RF、XGBoost 和 MLP 五种模型，具体流程如图 3-2 所示。

首先，使用 bge-large-zh-v1.5^[51]模型对文本进行嵌入，移除 L2 归一化。其次，对数据进行上采样以解决部分二级类别数据稀疏问题，并按 6:2:2 的比例划分训练集、验证集和测试集。在预处理阶段，LR、KNN 和 MLP 模型训练前对嵌入向量进行了 L2 归一化，而 RF 与 XGBoost 作为基于决策树的模型，其划分依赖于单一特征维度的阈值比较，不涉及向量距离或模长，且归一化可能破坏特征间

的独立性，因此未进行 L2 归一化处理。最后，通过网格搜索在验证集上确定最优超参数，并在测试集上评估模型性能，并使用模型对数据集 D1 的摘要进行预测，得到二级产品类别。

表 3-2 《医疗器械分类目录》的字段和值

字段	值
一级序号/产品类别	01 有源手术器械
二级序号/产品类别	01 超声手术设备及附件
三级序号/产品类别	01.1 超声手术设备
产品描述	通常由超声波发生器和带有外科尖端的手持部件组成，手持部件通常由一个换能器、一个连接构件和一个治疗头尖端组成。
预期用途	用于软组织的切割、止血、整形。
品名举例	软组织超声手术仪、外科超声手术系统、超声手术系统、超声切割止血刀系统、软组织超声手术系统、超声手术刀、超声刀系统
管理类别	III




图 3-2 二级产品类别分类模型

模型具体的结果如表 3-3 所示，Count 代表模型在数据集 D1 上预测出的二级产品类别数量，Value 代表模型在每个一级产品类别的测试集中 Precision 的最小

值。这两个指标分别从不同侧面反映了模型对数据分布和类别边界的刻画能力。

表 3-3 模型结果

模型	Count	Value
LR	198	0.9090
KNN	206	0.8882
RF	200	0.8476
XGBoost	201	0.7593
MLP	203	0.9378

Count 衡量的是模型对于二级类别的覆盖率,在进行二级分层抽样的情况下,如果模型可以准确识别更多的二级产品类别,则说明该模型对于各类别有较好的区分能力,有利于防止抽样过程中出现一些比较稀少或者样本数量较少的二级类产品被忽略,进而提高抽样结果在类别的完整性和代表性,KNN 在数据集 D1 上能识别所有的二级产品,因此它在类别的覆盖率上有较大优势。

而 Value 衡量的是以最差类别性能来评价模型的精确率,在最小 Precision 越高的情况下意味着模型对所有的一级类别的二级类别的预测错误被有效控制,特别是在难以区分或者界限不明的类别中仍然具有较好的识别能力,这有利于降低采样过程中由于系统性误判带来的标签噪声,而 MLP 获得最高的 Value,也即它在一级类别的预测更均匀。

Count 和 Value 分别从类别覆盖性和预测可靠性两个方面对二级分层抽样有影响,均可使得得到更优更具有代表性的标注样本集,具体的抽样效果可见 3.3.3 节。

3.2.2 抽样设计

为了使子集 D2 能较好反映整个数据集 D1 的分布特征,本文对数据集进行了一级类目分层、二级类目自适应抽取的方法进行抽样。对于每一个一级类目中的数据子集,本文提出了一个既有基本比例又有最低限度抽取以及总体数量保证补充的自适应方法来兼顾各个小类目的代表性的同时保证总的样本数量足够大。

算法 3-1 抽样算法伪代码

Adaptive Stratified Sampling with Minimum Constraint

Input: Data group G (subset of a primary category), Secondary stratification column

Col_{sec} , Sampling rate α , Minimum sample per subgroup τ , Minimum total samples M . Output:

Sampled subset S_{final} .

1. Initialize empty list $L_{samples}$
 2. for each subgroup g in G grouped by Col_{sec} do
 3. $N \leftarrow$ count of rows in g
 4. if $N \leq \tau$ then
 5. Add all rows of g to $L_{samples}$
 6. else
 7. $n_{target} \leftarrow \lceil N \times \alpha \rceil$
 8. $n_{extract} \leftarrow \max(n_{target}, \tau)$
 9. Randomly sample $n_{extract}$ rows from g , add to $L_{samples}$
 10. end if
 11. end for
 12. $S_{base} \leftarrow \text{concatenate}(L_{samples})$
 13. if $\text{size}(S_{base}) < M$ and Filling is enabled then
 14. $G_{remain} \leftarrow G \setminus S_{base}$
 15. $Need \leftarrow M - \text{size}(S_{base})$
 16. Calculate distribution weights W of Col_{sec} in G_{remain}
 17. Sample $Need$ rows from G_{remain} weighted by W
 18. $S_{final} \leftarrow S_{base} \cup S_{extra}$
 19. else
 20. $S_{final} \leftarrow S_{base}$
 21. end if
 22. return S_{final}
-

(1) 基础比例与最小阈值抽样

第一个步骤是遍历每个一级类别下面的所有二级类别 C_{sec} 。由于长尾类别在固定比例下采样的时候容易导致此类别样本数量不足,因此本文设置了一个最小样本数 τ 。对于每个二级类别 i ,令其总样本数目为 N_i ,那么就有如下步骤:如果 $N_i \leq \tau$,那么这个类别的所有样本都会被选取,尽可能多地保留这些稀有类别信息;否则当 $N_i > \tau$ 时,根据比例 α 计算出需要采样的样本数量 $n_{prop} = [N_i \times \alpha]$,最后选取的数量为 $n_{final} = \max(n_{prop}, \tau)$,这样可以保证主要类别的比例被放大,但是长尾类别的曝光度最小。

(2) 总量保底填充

基础抽样结束后,程序判断已抽取样本总数 S 是否小于所需的最小数量 M 。若 $S < M$,则执行填充操作。但是为了保持原有的第二级类别的比例关系,在填充时并不是简单地从剩下的所有样本中随机选取,而是根据剩余未抽取的数据中各个第二级类别的比例来决定各自要补充的数量。即求出还需要补充的数量 $K = M - S$,然后按照剩余数据中的各类别所占的比例为其分配相应的补充数量,最后将补充样本与基础样本合并得到最终的抽样结果。该抽样算法的伪代码见算法3-1。

综合考虑专家标注成本与评估结果的统计可靠性,本文将抽样算法中的参数设置为 $\alpha=0.012$ 、 $\tau=2$ 和 $M=30$,最终获得的子集 $D2$ 数据总量为1104条。

3.2.3 抽样结果评估

为定量评估抽样结果的分布一致性,本研究采用JS散度来衡量子集 $D2$ 和数据集 $D1$ 在类内相似度上的差异。

本文引入类内相似度指标定量刻画不同类别样本在语义空间中的聚集程度。设数据集中共有 C 个类别,第 c 类样本的集合记为 $D_c = \{x_1^c, x_2^c, \dots, x_{n_c}^c\}$,其中 $x_i^c \in \mathbb{R}^d$ 表示属于第 c 类的第 i 个样本的归一化语义向量, n_c 为该类别的样本数量。对于任一样本 x_i^c ,其相对于任意类别 c' 的平均相似度定义为该样本向量与类别 c' 中所有样本向量点积的均值,即:

$$\text{Sim}(x_i^c, c') = \frac{1}{|D_{c'}|} \sum_{x_j^{c'} \in D_{c'}} x_i^c \cdot x_j^{c'} \quad (3-1)$$

其中，“ $\cdot$ ”表示向量点积运算， $|D_{c'}|$ 表示集合 $D_{c'}$ 的势，即样本数量。基于此定义，可得出类内相似度指标，当 $c'=c$ 时， $\text{Sim}(x_i^c, c)$ 衡量了样本 x_i^c 与同类样本在语义空间中的平均紧密度。

具体而言，首先利用预训练文本嵌入模型 **bge-large-zh-v1.5** 将专利文本映射为高维语义向量表示，并对所有样本向量进行 L2 归一化处理，以消除向量模长差异，使向量间的点积等价于余弦相似度。

为了比较不同抽样子集与原始全集在类内相似度分布上的一致性，本文采用 **Jense-Shannon** 散度作为分布差异度量指标。JS 散度是一种基于 **Kullback-Leibler** 散度的对称且有界的分布距离度量，具有良好的数值稳定性，适合用于经验分布之间的比较。JS 散度取值范围取决于对数底数，本文采用以 2 为底的对数计算 JS 散度，JS 散度取值范围为 $[0,1]$ ，其值越小，表示两个分布越相似，即抽样数据在语义结构层面越好地保持了原始数据的分布特征。

本文采用 JS 散度而不是 **Kolmogorov-Smirnov** 检验或者 **t** 检验等传统统计显著性检验方法的原因在于：

（1）样本独立性假设的违背

传统的统计假设检验一般需要比较的两个样本是相互独立的，在这个实验中，抽样子集 **D2** 是总体 **D1** 的一个真子集，二者之间有天然的数据重叠以及内在的相关性，不符合两样本假设检验的前提假设，因此不能使用传统的检验方法进行分析。

（2）大样本下的过度敏感性

全集 **D1** 样本容量很大，在这种情况下，传统的统计检验对于很小的变化过于敏感，容易得到统计显著的结果，即 $p \rightarrow 0$ ，这不能很好地说明这两个样本集在业务逻辑上的一致性。因此相比于二元判断的显著性检验，使用一个有界的并且数值稳定 JS 散度可以更好地衡量抽样子集对于原始语义空间重构的质量。

本论文使用自助法 **Bootstrap** 来检验所得到的结果是否是稳健的。即以从 **KNN** 以及 **MLP** 模型预测出的所有二级产品类别构成集合 **D1** 为基础，通过上述

方法随机抽取 30 次，然后求每一次所抽到子集 D2 与整个集合 D1 之间的类内相似性分布的 JS 散度。

表 3-4 基于不同模型预测结果的抽样 JS 散度均值对比

一级产品类别	Better_Model	KNN_JS_Mean	MLP_JS_Mean
有源手术器械	mlp	0.062541642	0.059463533
医疗器械消毒灭菌器械	knn	0.161505414	0.165691608
有源植入器械	mlp	0.194804731	0.1841721
无源植入器械	mlp	0.206948514	0.184582234
注输、护理和防护器械	mlp	0.118928966	0.110467179
患者承载器械	mlp	0.16385814	0.155918799
眼科器械	mlp	0.157853983	0.145614531
口腔科器械	mlp	0.168319474	0.143221929
妇产科、辅助生殖和避孕器械	knn	0.175837643	0.181431399
医用康复器械	knn	0.163571089	0.164664325
中医器械	mlp	0.156370375	0.149115093
无源手术器械	mlp	0.05061372	0.046914115
医用软件	mlp	0.135186458	0.131656384
临床检验器械	knn	0.108278277	0.122580652
神经和心血管手术器械	knn	0.156878135	0.182865774
骨科手术器械	mlp	0.056881381	0.052935181
放射治疗器械	knn	0.164986065	0.178400641
医用成像器械	knn	0.029504861	0.033317317
医用诊察和监护器械	knn	0.044292479	0.045018019
呼吸、麻醉和急救器械	mlp	0.174426776	0.167441754
物理治疗器械	mlp	0.19472644	0.188764668
输血、透析和体外循环器械	mlp	0.159247257	0.151398573

不同的模型预测基础上抽取样本的比较见表 3-4。较小的 JS 散度均值说明在该模型预测结果的基础上，采样算法能更好地保持原始数据的语义分布特征，从

而间接反映该模型产出的类别结构具有较好的稳定性。在所有 22 个一级产品类目里，MLP 模型有 14 个类目的 JS 散度均值是最小，总体上优于 KNN 模型。

基于上述评估结果，本研究最终选择基于 MLP 模型的预测结果执行抽样，并设定 JS 散度阈值为 0.10，以严格控制子集的分布偏差，采用多随机种子优选策略。对每个一级类别，从[0,100000]范围内随机生成 30 个候选随机种子，分别抽样并计算抽样分布与原始分布的 JS 散度，最终选取使 JS 散度最小化的随机种子。最终的抽样参数及结果详见表 3-5，共获得 1104 条样本组成数据集 D2。在专家完成对数据集 D2 的标注工作后，该数据集将用于后续检验自动标注 workflows 的性能。

表 3-5 基于 MLP 的最终抽样结果

一级产品类别	随机种子	JS 散度	样本数
有源手术器械	26188	0.033737689	87
无源手术器械	3196	0.022548032	98
神经和心血管手术器械	34133	0.096770088	33
骨科手术器械	73197	0.024987938	93
放射治疗器械	47955	0.098357227	30
医用成像器械	86387	0.018465222	153
医用诊察和监护器械	49560	0.030922054	106
呼吸、麻醉和急救器械	44410	0.093776998	30
物理治疗器械	97968	0.098341415	30
输血、透析和体外循环器械	36487	0.096868525	30
医疗器械消毒灭菌器械	25224	0.080329158	30
有源植入器械	42267	0.075740376	30
无源植入器械	7809	0.091205331	30
注输、护理和防护器械	84598	0.052954787	52
患者承载器械	13402	0.087097231	30
眼科器械	65667	0.067403703	33
口腔科器械	69618	0.061515223	30

续表 3-5 基于 MLP 的最终抽样结果

一级产品类别	随机种子	JS 散度	样本数
妇产科、辅助生殖和避孕器械	69647	0.091536967	30
医用康复器械	38419	0.098865981	30
中医器械	21332	0.093469022	30
医用软件	61089	0.084989251	41
临床检验器械	5161	0.056356851	48

3.3 自动标注 workflow 构建

对于近 6 万条候选数据，逐条人工标注成本较高，且不同标注者之间也可能存在理解差异。本文使用 D2 作为评价基准，对自动标注 workflow 进行设计、优化和验证，再将其用于剩余数据的标签补全。

3.3.1 环境搭建

由于数据量以及成本原因，本文并没有采用 API 调用方式，在本地搭建了一个完全私有的推理以及调度环境，相关软硬件配置见表 3-6、表 3-7。

推理阶段使用 NVIDIA RTX 4060 显卡，在此显卡上集成了 AdaLovelace 架构，支持 FP8 以及 INT8 等低精度运算，在大规模模型量化推理场景下适用，由于 Qwen3:8B 模型所需显存为 8GB，所以此显卡也足够用于本地部署。

在模型推理层面，使用 Ollama^[52]作为本地大语言模型运行时，在此进行模型加载、量化推理以及服务化部署等工作，该方式减少了重复部署和接口适配工作，并提高了本地推理服务的稳定性。

在应用及编排方面，本文使用 Dify 进行 LLM 的应用开发以及工作流的实现，同时采用 Docker^[53]的方式对应用进行容器化部署以便提供一致的操作环境并且便于复制。

表 3-6 硬件详情

硬件组件	规格
GPU	NVIDIA GeForce RTX 4060 Laptop GPU
显存	8GB
操作系统	Windows 11 (x64)

表 3-7 软件详情

软件	版本
CUDA Toolkit	12.8.93
Docker	28.3.2
Python	3.11.4
Ollama	0.13.5
Dify	1.6.0

3.3.2 自动标注 workflows 设计

医疗器械专利文本具有专业术语密集、类别边界模糊和功能描述交叉等特点。单纯依赖 LLM 内部知识容易出现过度泛化，单纯依赖关键词匹配又难以理解器械用途。因此，本文在 Dify 中构建了 RAG 知识检索结合规则提示与条件纠错的自动标注 workflows，如图 3-3 所示。




图 3-3 自动标注 workflows

(1) 知识检索模块

本模块用于指导大模型进行正确分类。系统接收到一个专利摘要后，使用 bge-large-zh-v1.5 嵌入模型将其转化为向量表示。然后，在已经建立好的《医疗器械分类目录》知识库中进行混合搜索，语义以及关键词所占比例分别为 0.7、0.3，Score 阈值为 0.4，返回与输入摘要语义最接近的前五个知识片段。这些片段包含了相关类别的定义、核心特征及典型产品示例，为后续的推理过程提供了权威的知识上下文。

(2) 初步分类决策模块

本文在系统提示词中补入国家市场监督管理总局发布的《医疗器械分类规则》中的关键定义，包括有源医疗器械、无源医疗器械、植入器械和独立软件等概念。同时，本文将“有源与无源”“植入与手术器械”“临床检验与诊察监护”“医用软件与硬件器械”等易混类别整理为区分重点，要求模型优先依据专利摘要中的主要功能、工作原理和使用场景进行判断。

Qwen3:8B 根据专利摘要、检索到的目录片段和系统提示词输出一级产品类别。输出被约束为结构化 JSON 格式，字段包括类别，结构化输出可减少后续解析错误，也便于对多轮输出进行一致性统计。

表 3-8 各分支及作用

分支	作用
有源植入器械	当初步判定为“有源植入器械”时，进入该分支。专门的 LLM 节点会重点对比“有源植入器械”与“有源手术器械”，通过检查是否“长期留置体内”及“是否依赖能源驱动”等核心特征进行最终确认。
医用诊察和监护器械	针对该类别与“医用软件”的界限模糊问题，校验节点重点分析核心创新点是在于硬件传感器还是数据处理算法。
无源植入器械	重点区分“无源植入”与“有源植入”，严格排查摘要中是否包含“电极”、“传感器”等暗示有源属性的关键词。
医用康复器械	鉴于康复器械常与“医用软件”或“患者承载器械”混淆，该分支重点判断设备的主要功能是“功能恢复训练”、“单纯承载”还是“纯算法分析”。

（3）条件分支纠错模块

为避免初筛过程中出现误判情况，在工作流中增加条件分支以对某些类目再次甄别。基于前期测试结果，发现四个高频易混类别并分别为其设置专门纠错节点，如表 3-8 所示。

（4）变量聚合与输出

变量聚合器汇总各分支最终结果，无论样本经过何种分支路径，系统最终均输出统一格式的分类标签，用于完成单条专利的自动标注。

该设计并不等同于对 LLM 进行垂直领域微调，但通过分类目录 RAG、分类规则提示和分支纠错，将领域知识嵌入标注过程，形成了可复现的领域适配流程。

3.3.3 自动标注结果评估

为了测试自动标注工作流的效果以及控制最终生成标签的质量，在专家对数据集 D2 进行标注后，对自动标注工作流进行定量评价。在实验过程中，本文根据 D2 上的错误样本不断调整 RAG 检索参数、LLM 提示词和 LLM 生成参数，并增加针对易混类别的条件分支检查。这个过程并不是简单比较一次输出，而是围绕 D2 校对结果逐步收敛工作流。

由于 LLM 生成具有一定随机性，为获得较稳定的标注结果，本文将 LLM 的温度和 Top-P 均设为 0.5，使模型输出相对保守。随后，本文在 D2 上重复运行 10 轮自动标注工作流，并以 10 次结果中的众数作为该样本的最终工作流标签。若多轮输出高度一致，说明该工作流对同一输入的判定较稳定；若多轮结果分散，则说明该样本可能处于类间边界或提示词约束不足。

本研究选取了以下三个核心指标对标注质量进行多维度评估：

（1）Accuracy

衡量模型整体分类正确的样本比例，直观反映标注的总体精度。

（2）Macro F1-score

求所有类别的 F1 分数均值。但由于医疗器械类别分布极不平衡，MacroF1-score 更能真实体现模型对于稀有类别性能，而不会被大多数类别所影响。

(3) Fleiss' Kappa 系数

用来衡量 10 次运行的结果是否一致。Kappa 值越大，说明模型在不同的轮次所得到的结果越一致，随机性的成分就越小。

表 3-9 不同标注方法在 D2 上的对比结果

方法	Accuracy	Macro F1-score	说明
Original	0.5833	0.5535	数据原始标签
Keyword	0.3324	0.2428	BM25 关键词匹配
KNN+BGE	0.6141	0.5454	基于目录嵌入的 KNN 加权投票
本文工作流	0.9321	0.9220	分类规则+分类目录 RAG+纠错分支

表 3-9 结果显示，原始标签的 Accuracy 为 0.5833，说明原始标签不能直接作为高质量训练真值。Keyword 方法受限于词面匹配，Macro F1-score 仅为 0.2428；KNN+BGE 引入语义嵌入后 Accuracy 提升到 0.6141，但仍难以处理功能边界复杂的专利摘要。完整结构的 Accuracy 达到 0.9321，Macro F1-score 达到 0.9220，明显高于原始标签、词法匹配和语义向量匹配方法。这说明，医疗器械专利一级产品类别标注不能只依赖词面重合或向量近邻，还需要引入分类规则、目录知识和针对易混类别的纠错判断。

表 3-10 自动标注工作流的领域知识消融结果

方法	分类规则	分类目录	纠错	Accuracy	Macro F1-score	Fleiss' Kappa
LLM-Zero-Shot	否	否	否	0.5326	0.4941	0.9943
LLM-Prompt	是	否	否	0.7032	0.6127	0.9958
LLM-Prompt-RAG	是	是	否	0.8958	0.8801	0.9972
完整结构	是	是	是	0.9321	0.9220	0.9986

为进一步说明完整结构中各组成部分的作用，本文开展自动标注工作流的消融实验。消融实验只比较同一 LLM 工作流下的内部变体：LLM-Zero-Shot 作为不注入领域知识的起点，LLM-Prompt 加入《医疗器械分类规则》，LLM-Prompt-RAG 继续加入《医疗器械分类目录》RAG，完整结构在此基础上加入纠错分支。这样划分可以避免将不同技术路线的对比实验与同一方法内部组

件消融混在一起。

消融结果表明，领域规则可以帮助 LLM 建立有源/无源、植入/非植入等基本判断框架；分类目录 RAG 提供更贴近产品类别的外部知识，是性能提升的主要来源；纠错分支则针对易混类别进一步压缩错误空间。

为观察完整结构在不同类别上的错误分布，本文进一步绘制 D2 上的混淆矩阵，如图 3-4 所示。可以看到，大部分样本集中在主对角线上，说明预测标签与专家校对标签整体一致。其中，样本量较大的“医用成像器械”“医用诊察和监护器械”和“无源手术器械”分别有 193 条、183 条和 120 条样本被正确识别，构成矩阵中最主要的正确分类区域；“骨科手术器械”“医用软件”“有源手术器械”等类别也在对角线上形成较明显的集中分布。




图 3-4 workflow 在 D2 上的混淆矩阵

非对角线位置的错误数量相对较少，且主要集中在语义或功能边界接近的类别之间。例如，医用成像器械与医用诊察和监护器械都可能涉及超声、信号采集

和图像处理等表述；有源手术器械与无源手术器械的差异依赖于摘要中是否明确出现能源驱动特征；无源手术器械、骨科手术器械和神经心血管手术器械之间也会因手术场景或解剖部位描述不充分而出现混淆。

混淆矩阵结果与表 3-10 中完整结构的 Accuracy 为 0.9321、Macro F1-score 为 0.9220 相吻合，说明该工作流在多数类别上具有较稳定的标注效果，但在功能边界接近或摘要关键信息不足的样本上仍存在少量误判。

3.3.4 案例分析

为进一步说明不同标注方法的差异，本文选取三条具有代表性的 D2 样本进行案例分析。案例分别对应逐级修正、纠错修正和失败边界三种情况。

案例一为 CN200910105446.X “肝脏纤维化检测装置”。该专利摘要包含“超声探头”“回波电信号”等词，Keyword、LLM-Zero-Shot 和 LLM-Prompt 均将其标为“医用成像器械”。但其核心功能是检测肝脏纤维化程度并输出实时定量信息，属于诊察与监护，而非获取结构影像。RAG 检索到与组织硬度检测、纤维化评估相关的目录条目后，LLM-Prompt-RAG 和完整结构均修正为“医用诊察和监护器械”。该案例说明，分类目录知识能够纠正由表层技术词引起的误判。

案例二为 CN202011051118.9 “一种结合药物递送的深部柔性脑电极的植入方法”。LLM-Prompt-RAG 将其误判为“无源植入器械”，原因是摘要中存在“柔性”“蛋白保护层”等材料表述，容易指向无源植入。完整结构在纠错分支中识别到“脑电极”和“植入方法”等关键信息，并依据“电极一般属于有源植入器械”的区分规则，将结果修正为“有源植入器械”。这说明纠错模块具有独立价值，不只是对主 LLM 结果的形式化包装。

案例三为 CN202110898105.3 “一种肝胆外科临床用取石装置”。该摘要主体大量描述滑块、弧形板、弹性铰链等机械结构，完整结构最终输出“无源手术器械”，但摘要末尾出现“碎石电极击碎结石”，正确类别应为“有源手术器械”。该样本显示，当关键分类信息在摘要中占比很低，且主 LLM 输出结果未触发相应纠错分支时，工作流仍可能失败。保留这类失败案例，有助于界定方法边界。

3.4 置信度过滤与最终数据集

自动标注结果不能只看 D2 上的整体指标。真正用于第四章训练的，是未进入 D2 的大量样本。若直接使用全部自动标签，低质量样本仍可能进入训练集。为此，本文基于 D2 分析原始标签与 workflow 标签的一致性，将其作为置信度划分依据。

D2 中每个样本有两个相互独立的标签信号，一是原始标签，二是本文自动标注 workflow 输出标签。两者错误来源不同。若二者一致，说明该样本被两个独立来源同时归入同一类别，标签可靠性应更高；若二者不一致，则样本更可能存在原始标签错误。D2 上的统计结果见表 3-11。

表 3-11 D2 中原始标签与 workflow 标签一致性的置信度统计

置信层	条件	D2 占比	正确率	错误率
高置信	原始标签=workflow 标签	56.25%(621/1104)	97.91%(608/621)	2.09%
低置信	原始标签≠workflow 标签	43.75%(483/1104)	87.16%(421/483)	12.84%

高低置信层错误率相差 10.75 个百分点，说明双信号一致性可以作为有效的错误检测机制。随后，本文对 D3 样本进行置信度标记。D3 指原始候选数据中扣除 D2 后的未校对样本。标记结果显示，高置信样本 33327 条，占 58.07%；低置信样本 24064 条，占 41.93%。

为了验证 D3 置信层质量是否与 D2 中观察到的规律一致，本文按 22 个一级类别和高低置信层进行交叉分层抽样，其中高置信层抽取 440 条、低置信层抽取 330 条，并进行专家校对，结果见表 3-12。

表 3-12 D3 置信层抽样验证结果

置信层	抽样正确率	与 D2 同层对比
高置信	96.59%(425/440)	D2 高置信为 97.91%，差距 1.32 个百分点
低置信	82.12%(271/330)	D2 低置信为 87.16%，差距 5.04 个百分点

仅凭抽样正确率仍不足以判断 D3 高置信层能否作为训练数据使用。因此，本文进一步采用 TOST 等价性检验，以 D2 同层准确率作为参照基准，等价边界设为 3%，显著性水平设为 0.05，检验结果见表 3-13。

表 3-13 D3 置信层 TOST 等价性检验结果

置信层	观测 Accuracy	90%CI	等价区间	TOST 结论
高置信	96.59%	(95.17%, 98.01%)	(94.91%, 100.91%)	通过
低置信	82.12%	(78.65%, 85.59%)	(84.16%, 90.16%)	未通过

检验结果表明，D3 高置信层与 D2 高置信层在统计意义上等价，可以作为训练数据保留；D3 低置信层未通过等价性检验，且其准确率明显低于 D2 整体水平，继续使用会增加训练标签噪声。因此，本文过滤 D3 低置信样本，仅保留 D3 高置信样本 33327 条，并与 D2 的 1104 条专家校对样本合并，得到 34431 条高质量标注数据。

3.5 数据增强

置信度过滤提高了标签质量，但也放大了部分类别的长尾问题。过滤后，“输血、透析和体外循环器械”仅有 31 条样本，是所有类别中样本量最少的一类。是否需要增强，不能只按样本数量判断。本文采用训练过程中的可学习性作为依据，若某类别在常规训练中测试集 Recall 持续为 0 或接近 0，则说明模型难以学习到该类别的有效边界，才对该类别进行增强。

在不使用增强数据时，“输血、透析和体外循环器械”在前 8 轮训练中的测试集 Recall 均为 0，第 9 轮才达到 0.33，F1-score 为 0.50。与之相比，样本量为 98 条的“医疗器械消毒灭菌器械”在第 2 轮训练时 Recall 已达到 0.89，此后保持较高水平。也就是说，在本研究中 31 条样本对应的类别处于模型难以学习的区间，而 98 条及以上的少样本类别已具备基本可学习性。因此本文仅对“输血、透析和体外循环器械”进行 LLM 数据增强。增强时，本文从该类别真实专利中提取独立权利要求和第一权利要求，将其中的技术内容作为输入，要求 LLM 在不改变关键技术实体、技术逻辑和技术边界的前提下改写为摘要形式文本。最终生成 62 条增强摘要，使该类别样本量由 31 条增加到 93 条。

专利文本具有较强的技术严谨性，生成式增强不能只看文本是否通顺。本文对生成摘要进行专家核验，重点检查三个方面，关键实体是否保留，实体之间的技术关系是否自洽，生成文本是否引入原文未披露的技术特征。通过核验后的增

强样本才进入最终训练集。

在人工核验之外，本文使用 `bge-large-zh-v1.5` 嵌入向量计算余弦相似度，作为语义层面的辅助证据。这里比较三组相似度。第一组是“增强摘要与来源专利摘要”，即每条生成摘要和其对应原专利摘要之间的相似度，用来观察改写后是否仍贴近原文。第二组是“原始同类专利两两之间”，即 31 条真实的输血、透析和体外循环器械专利之间的两两相似度，用来表示同一类别内部不同真实专利的自然差异。第三组是“增强摘要两两之间”，用来观察生成样本之间是否过度相似，结果见表 3-14。

表 3-14 LLM 增强摘要与原始摘要的 BGE 相似度分析

指标	生成摘要与对应原文	原始同类专利之间	生成摘要之间
样本数	62	465	1891
均值	0.8310	0.5637	0.6397
标准差	0.0722	0.0983	0.0867
最小值	0.6360	0.3586	0.3760
最大值	0.9607	0.8402	0.9873
P50	0.8375	0.5550	0.6381
P95	0.9502	0.7446	0.7737

表 3-14 结果显示，生成摘要与对应原文的平均相似度为 0.8310，高于原始同类专利之间的平均相似度 0.5637。这说明生成摘要与其来源专利的语义关系，比同类别中两件不同真实专利之间的语义关系更接近。即使在最低值处，生成摘要与对应原文的相似度仍为 0.6360，高于原始同类专利之间的平均水平。与此同时，生成摘要之间的平均相似度为 0.6397，低于生成摘要与对应原文的 0.8310，说明生成样本没有简单聚集为高度重复的文本。

上述结果从语义向量角度说明，增强摘要整体上贴近来源专利，未表现出明显语义偏移。最终，本文将 34431 条过滤后数据与 62 条增强数据合并，形成 34493 条训练数据，用于第四章分类模型训练与评估。

第四章 分类模型设计与评估

本章面向第三章构建的医疗器械发明专利数据集开展一级产品类别分类模型的设计与评估工作。分类任务的目标是根据发明专利文本内容，将其归入《医疗器械分类目录》规定的 22 个一级产品类别。考虑到专利文本篇幅较长、术语密集，不同类别之间又存在一定语义重叠，本文分别考察传统机器学习方法和基于预训练语言模型的深度学习方法，并通过模型对比、消融实验和外部验证分析不同方法在本文数据集上的适用性。

4.1 分类模型设计

4.1.1 机器学习模型

为了进行基准比较，在此基础上实现四种机器学习分类方法，KNN、LR、RF 以及 XGBoost，分类过程见图 4-1。




图 4-1 机器学习分类流程

具体而言，首先对原始专利文本数据进行预处理，利用 bge-large-zh-v1.5 模型将文本转换为高维向量表示，然后按照 8:1:1 的比例划分训练集、验证集和测

试集。考虑到文本向量的高维稀疏性，为了消除样本长度差异带来的影响并提升计算效率，本研究采用 L2 归一化对特征向量进行处理。随后，为了进一步降低特征维度并去除噪声，应用主成分分析技术将向量维度降至 128 维。在模型训练阶段，采用 5 折交叉验证结合网格搜索策略，以 Macro F1-score 为优化目标，对 KNN、LR、RF 和 XGBoost 四种模型的超参数进行寻优，最终在测试集上评估其分类性能。

4.1.2 深度学习模型

在构建深度学习模型前，在原始数据集上对第二章提到的三种候选预训练模型进行泛化能力比较，以选取最适配医疗器械领域预训练模型为基础，降低后续全部微调工作量。

具体地，使用线性探测的方法，在保持预训练模型大部分参数固定的情况下，在其最上面增加一个可以训练的线性分类器，对含有 22 类的数据集进行实验，为避免由于随机初始化导致的影响，设置 10 个不同的随机种子重复实验多次。这种方法用较少的时间就可以得到不同的预训练模型所学到的语义信息对于该分类任务具有良好的线性可分性。




图 4-2 预训练模型泛化性能评估

如图 4-2 所示，chinese-roberta-wwm-ext 在各轮测试中均保持较高的平均准确率。第 1 个 Epoch 时，该模型的平均测试准确率为 0.3242，分别高于

bert-base-chinese 的 0.2680 和 chinese-macbert-base 的 0.2264; 训练至第 10 个 Epoch 后, 其平均准确率达到 0.5526, 仍高于 bert-base-chinese 的 0.4936 和 chinese-macbert-base 的 0.4273。该结果说明, chinese-roberta-wwm-ext 在本文任务中具有较好的初始表征能力和持续学习能力。

综合以上结果可见, chinese-roberta-wwm-ext 具有较好的零样本特征提取能力, 初始表现较优, 且随训练轮次增加呈现较稳定的提升趋势。这说明该模型在预训练阶段已学习到一定的中文医学语义信息。因此, 本文采用 chinese-roberta-wwm-ext 开展后续微调实验, 以在分类效果和计算成本之间取得相对平衡。

为更好挖掘专利文本内部所隐含深层次语义信息并且能够准确地区分各类别局部重要部分, 本文构建基于预训练语言模型以及卷积神经网络相结合混合模型即 BERT-TextCNN, 在此基础上利用 BERT 获取整体上下文信息同时使用 TextCNN 获取局部重要部分信息, 具体结构见图 4-3 由三部分组成: BERT 编码层、双路特征抽取层及融合分类层。




图 4-3 BERT-TextCNN 架构

(1) BERT 编码层

使用 Chinese-RoBERTa-WWM-Ext 作为基础模型, 在对输入文本进行分词并

且将其截断或者补全到一定长度 $L=512$ 之后得到输入文本 $X \in \mathbb{R}^{B \times L}$, B 是批量大小, 通过 BERT 得到每一层的表示形式 $H \in \mathbb{R}^{B \times L \times D}$, 隐藏单元数 $D=768$ 。

为兼顾预训练模型的通用语言能力与其对医疗器械领域特定分布的适应性, 本文采用分层微调策略。即固定 BERT 最底层的 11 个 Transformer 编码器层参数只对最高一层即第 12 层进行微调。这样做可以大大降低需要优化的参数数量从而降低计算成本, 还可以避免因少量样本导致的灾难性遗忘以及过拟合问题。

(2) 特征提取层

为使得得到更丰富语义信息, 在此层采用全局特征通路和局部特征通路相结合方式进行特征学习。

全局特征通路用于获取整个句子的信息。从 BERT 输出的 [CLS] 标记向量 $h_{cls} \in \mathbb{R}^D$ 开始, 接着计算所有有效 Token 平均池化向量 $h_{mean} \in \mathbb{R}^D$, 忽略 [CLS]、[SEP] 以及 Padding。然后将这两个向量连接成一个大小为 $2D$ 维的初始全局向量, 再用一个全连接层将其映射到大小为 $d_{proj}=656$, 并且使用 ReLU 激活函数以及一层 BatchNormalization 后得到最后的全局特征向量 $v_{global} \in \mathbb{R}^{656}$ 。

局部特征通路用于通过 TextCNN 提取不同尺度的 N-gram 局部信息, 输入是 BERT 输出的 H 。使用四个不同的宽度的一维卷积核 $K \in \{2, 3, 4, 5\}$, 每个卷积核所对应通道数为 $N_k = \lfloor L/k \rfloor$, 分别是 256、170、128 以及 102。然后在经过卷积之后, 对于每一个特征图执行全局最大池化获取最关键的部分并把它们连接起来形成一个大小为 $\sum N_k = 656$ 的局部特征向量 v_{local} , 接着再做一层 LayerNormalization。

(3) 融合分类层

该部分负责综合全局以及局部信息并完成分类任务, 在此将全局特征 v_{global} 与局部特征 v_{local} 进行连接形成长度为 1312 融合特征表示量 v_{fusion} , 为以提高模型鲁棒性, 本文还对这些融合特征进行了层标准化和 Dropout 操作, 然后将该特征送入由多个隐藏层构成的全连接神经网络, 其中第一层将大小为 1312 映射到大小为 44, 经过 ReLU 激活之后, 第二层再将大小为 44 映射到大小为类别数量即大小为 22, 最后输出各个类别的非归一化概率。

为了使模型可以学到医疗专利文本深层次信息并且有较好鲁棒性, 本文设计了合理的数据集切分方法、损失函数优化方式及参数更新规则等。

（1）数据集划分

本文使用分层抽样的方式将得到的数据集分为训练集、验证集以及测试集，比例是 8: 1: 1，这样可以使得这三个部分中每一种类别的样本数量都与原数据集中相同的比例保持一致，避免由于类别不平衡而导致的影响评价准确性的问题，使实验更具说服力。

（2）损失函数设计

为了提高模型泛化能力和防止过拟合，在本研究中使用带有标签平滑正则化交叉熵作为损失函数，在此基础上设定平滑参数 $\epsilon=0.1$ ，将原本非零即一硬标签软化为概率分布更平滑的软标签，即给真实类别的概率加上一个小值同时减少其他类别的概率同样一个小值，这有利于防止模型在训练时过于确定自己的预测结果，使得到达的聚类更加紧密，从而大大提高对于未参与训练的测试集的效果。

（3）优化器与学习率调度

对于超参数优化使用 AdamW 优化器来更新梯度，在 Adam 基础上解耦权重衰减，更适合稀疏梯度情况，初始学习率为 5×10^{-5} ，权重衰减系数为 1×10^{-3} 。另外，为了使模型从局部最优解中跳出来并且找到更好的全局最优解，本文引入 ReduceLROnPlateau 动态学习率调度方法，在每个 epoch 结束之后检查验证集上损失函数的变化情况，如果在接下来两个 epoch 中没有降低，则将当前的学习率乘以一个因子 Factor=0.5。这样可以在一开始让模型迅速下降同时也可以后期更精确地微调参数。

4.2 分类模型评估

4.2.1 模型对比实验

为了检验 BERT-TextCNN 在医疗器械专利分类任务中的实际效果，结合第二章对专利表示模型和近年文本分类模型的梳理，本文的对比实验覆盖传统机器学习方法、专利文本表示模型和近年文本分类模型三类方法。传统机器学习方法先在 KNN、LR、RF 和 XGBoost 中进行预实验，最终选取测试集中表现最好的 KNN 作为传统方法代表；深度学习对比方法包括 DeepPatent^[54]、PatentSBERTa^[27]、PaECTER^[33]和 RAMHA^[34]。其中，DeepPatent 属于较早的专利分类深度学习结构，

采用词嵌入与卷积网络进行文本建模；PatentSBERTa 和 PaECTER 均与专利文本表示学习相关，本文将其迁移到医疗器械专利数据集上进行微调；RAMHA 虽然并非专利领域方法，但属于近年文本分类模型，其结构在文本分类任务中具有一定代表性，故作为近年文本分类方法的参照组。

为保证比较过程尽量公平，上述模型均在本文构建的数据集上重新训练或微调，训练集、验证集、测试集划分保持一致，主要训练参数也与本文模型保持一致。实验结果见表 4-1。

表 4-1 模型对比

模型	Accuracy	Macro F1-score	Weighted F1-score
KNN	0.8942	0.7461	0.8884
DeepPatent	0.8945	0.7951	0.8910
PatentSBERTa	0.9128	0.8430	0.9121
PaECTER	0.9217	0.8572	0.9210
RAMHA	0.9232	0.8655	0.9220
BERT-TextCNN	0.9261	0.8792	0.9249

表 4-1 结果显示，BERT-TextCNN 在 Accuracy、Macro F1-score 和 Weighted F1-score 上均取得最高值。其中，本文模型的 Accuracy 为 0.9261，比 KNN 高 3.19 个百分点；Macro F1-score 为 0.8792，比 KNN 高 13.31 个百分点。这个差距在 Macro F1-score 上更明显。换言之，本文模型并非只在样本较多的类别上获得较高正确率，也对样本量较少的类别保持了更稳的识别能力。

与近年文本分类和专利表示模型相比，BERT-TextCNN 的提升幅度不大，但方向较一致。相较于 RAMHA，本文模型的 Accuracy 提高 0.29 个百分点，Macro F1-score 提高 1.37 个百分点；相较于 PaECTER，Accuracy 提高 0.44 个百分点，Macro F1-score 提高 2.20 个百分点。该结果表明，单纯迁移通用文本分类结构或专利预训练表示并不能完全解决医疗器械专利的类别边界问题，局部器械术语、结构短语和用途短语仍需要在分类层面进一步建模。

DeepPatent 的 Accuracy 为 0.8945，Macro F1-score 为 0.7951，在几组深度模型中最低。该结果可能与其模型结构有关，传统词嵌入与卷积网络可以捕捉局部词序模式，但面对中文专利摘要中较强的技术性表述时，对上下文关系的建模仍

显不足。PatentSBERTa 和 PaECTER 的表现优于 DeepPatent，说明专利语料上的预训练表示对该任务确有帮助；但二者并未专门面向医疗器械分类目录进行结构适配，所以在小类召回上仍落后于本文模型，虽然差别不算悬殊，却足以说明模型适配有必要。

为了更好地了解模型对各类别进行分类以及错分的原因，本文绘制了 BERT-TextCNN 在测试集上的混淆矩阵，见下图 4-4。

混淆矩阵中，对角线区域明显高于非对角线区域。例如，“医用成像器械”被正确分类的样本数为 958 个，“医用诊察和监护器械”被正确分类的样本数为 590 个，“无源手术器械”和“有源手术器械”被正确分类的样本数分别为 389 个和 270 个。这说明模型在主要类别上具有较好的区分能力。




图 4-4 BERT-TextCNN 模型的混淆矩阵

误判主要集中在语义相近的器械类别之间。以手术器械相关类别为例，“骨科手术器械”中有 14 个样本被划入“无源手术器械”，另有 6 个样本被划入“有

源手术器械”；“无源手术器械”中有 17 个样本被划入“有源手术器械”。这类误判并不意外。骨科器械、无源手术器械和有源手术器械在专利文本中经常共同出现“牵开”“固定”“刀头”“夹持”等结构和动作描述，模型较容易把局部术语相似性当成类别判据。

“医用软件”与“医用诊察和监护器械”之间也存在一定混淆，其中有 21 个“医用软件”样本被划入“医用诊察和监护器械”。这与实际专利写法有关，许多软件类专利服务于监护、诊断或图像处理场景，摘要中常把算法、监测流程和设备端功能放在一起描述。当文本更强调使用场景而不是软件属性时，模型会更倾向于输出对应的器械类别。

“临床检验器械”中有 6 个样本被划入“医用诊察和监护器械”，另有 7 个“注输、护理和防护器械”样本被划入“临床检验器械”。这说明模型在处理检验、护理、监测等临床流程交叉场景时仍有误差。换句话说，模型能够识别大部分一级类别，但在跨流程、跨部件的复合型专利上仍依赖更细粒度的语义判别。

总体来看，混淆矩阵与表 4-1 的指标相互印证，BERT-TextCNN 在总体正确率上较高，在多数类别上也能保持稳定输出，但对于术语重叠度高、应用场景相互嵌套的类别仍存在一定错分。

表 4-2 训练参数

参数	值
batch_size	64
lr	5.0e-05
weight_decay	0.001
epochs	50
patience	3
dropout	0.2
kernel_sizes	2,3,4,5
freeze_layers	11
max_length	512

最后给出模型训练时使用的参数以及所用到的软硬件环境，本文中的实验环境以及模型最终使用超参数见表 4-2、表 4-3 与表 4-4 中所述内容。所有的实验

均是基于 PyTorch 进行编写并在配有较高性能的 GPU 服务器上训练。

表 4-3 硬件环境

硬件组件	规格
GPU	NVIDIA Tesla P100-PCIE-16GB * 8
显存	16G * 8
操作系统	Windows server 2019

表 4-4 软件环境

软件	版本
CUDA Toolkit	12.0.76
Python	3.12.11

4.2.2 消融实验

为了判断模型性能来自何处，本节在相同实验设置下设计两组消融实验：一组考察定向数据增强对分类结果的影响，另一组考察微调策略与 TextCNN 结构对模型结果的影响。这样处理可以避免只给出最终模型分数，而无法解释分数来源的问题。

数据层面的消融实验旨在验证生成式数据增强对模型性能的具体影响，实验结果如表 4-5 所示。

表 4-5 数据增强结果

实验设置	Accuracy	Macro F1-score	Weighted F1-score
未使用数据增强	0.9245	0.8408	0.9235
使用数据增强	0.9261	0.8792	0.9249

表 4-5 结果显示，使用定向数据增强后，Accuracy 由 0.9245 提升至 0.9261，Weighted F1-score 由 0.9235 提升至 0.9249，变化幅度较小，这与增强策略有关。本文只对一个最小类别进行增强，并未改变多数类别的样本分布，因此总体正确率不会出现大幅变化。更值得关注的是 Macro F1-score 由 0.8408 提升至 0.8792，提升 3.84 个百分点。由于 Macro F1-score 不受大类样本数量主导，该结果说明定向增强主要改善了极少数类别的学习效果。

进一步观察训练过程可知，“输血、透析和体外循环器械”在未增强时多轮

训练中召回率为 0，模型难以形成稳定分类边界；加入增强样本后，该类别在后续训练中逐步被识别。该结果表明，数据增强在本文中的作用并不是全面提高所有类别的分类结果，而是缓解极少数类别因样本不足导致的不可学习问题。

为考察预训练微调与混合特征提取相结合的有效性，在此基础上本文又设计四种不同组合方式的模型进行比较分析如表 4-6 所示。

表 4-6 模型架构消融实验

实验设置	Accuracy	Macro F1-score	Weighted F1-score
BERT+Linear（无微调）	0.8275	0.6775	0.8194
BERT+Linear（微调）	0.9154	0.8520	0.9132
完整结构（不微调）	0.9125	0.8377	0.9094
完整结构（微调）	0.9261	0.8792	0.9249

模型架构消融实验结果显示，微调对模型效果影响较大。BERT+Linear 在不微调时 Macro F1-score 为 0.6775，微调后提升到 0.8520，说明通用预训练表示不能直接覆盖医疗器械专利中的类别差异。经过微调后，模型更容易关注与分类目录相关的词语和上下文关系。

TextCNN 结构也带来了稳定收益。在不微调 BERT 的情况下，完整结构的 Macro F1-score 为 0.8377，高于 BERT+Linear 无微调实验的 0.6775；在微调条件下，完整结构的 Macro F1-score 为 0.8792，也高于 BERT+Linear 微调实验的 0.8520。这说明卷积通路对局部短语具有补充作用。对专利文本而言，类别判别常常落在少数结构词和用途词上，单个[CLS]向量不一定能稳定保留这些细节。

从模型训练角度看，完整结构（不微调）也可以在一定程度上视为模型侧领域知识消融。由于本文采用的基础编码器 Chinese-RoBERTa-WWM-Ext 并非基于专利语料或医疗器械语料继续预训练得到，不微调时模型主要提供通用中文语义表示，微调后模型才进一步学习医疗器械专利文本中的术语分布和类别边界。

从结构消融看，本文模型的收益来自微调和 TextCNN 两个方面。微调使预训练模型向医疗器械专利语义分布靠近，而 TextCNN 补足局部术语组合的提取能力。本文的模型不是简单追求结构复杂度，而是在一级分类任务中把全局语义和局部判别词组放在同一分类框架下进行学习，这一点与表 4-1 中的近年模型对比结果能够相互对应。

4.2.3 外部验证

为考察模型在新专利数据上的适应性和时效性，在此基础上建立了一个 330 条的外部测试集，它们来源于医知桥^[36]平台 2025 年最新的发明专利。该平台存在将非医疗器械发明专利误归类的情况，因此，本文选择的数据是实际为医疗器械发明专利，且医知桥平台也将其归为医疗器械发明专利的数据，并由专家对这些样本进行人工复核和标注。

需要指出的是，外部验证集仍有边界。数据来自同一类专利文本，且医知桥是目前较少提供医疗器械分类目录标签的平台，外部来源并不丰富。因此，该实验更适合作为时效性和应用可行性的初步检验，而不能直接等同于对全部产业场景的充分证明。

基于该数据集，本文将训练完成的 BERT-TextCNN 模型与医知桥平台已有分类结果进行比较实验，见表 4-7。

表 4-7 外部验证集评估结果

评估对象	Accuracy	Macro F1-score	Weighted F1-score
医知桥	0.7515	0.7538	0.7352
BERT-TextCNN	0.8424	0.8546	0.8428

由表 4-7 可见，BERT-TextCNN 在外部验证集上的 Accuracy 为 0.8424，Macro F1-score 为 0.8546，Weighted F1-score 为 0.8428；医知桥对应指标分别为 0.7515、0.7538 和 0.7352。本文模型在 Accuracy 上提高 9.09 个百分点，在 Macro F1-score 上提高 10.08 个百分点。由于 Macro F1-score 对小样本类别更敏感，这一结果说明本文模型在外部数据上不仅提高了总体正确率，也改善了类别间表现不均衡的问题。

330 条样本能够反映 2025 年部分新增专利的分类情况，但样本规模和来源范围有限，尚不能覆盖所有医疗器械专利申请场景。就本文研究目标而言，该实验说明模型具备一定的跨时间数据适应能力，更大规模、多来源的外部验证仍需后续工作中继续完成。

第五章 系统设计与实现

前述章节完成了医疗器械发明专利分类数据集构建、分类模型训练与实验评估。为了检验分类模型在实际应用场景中的可用性，本文在模型研究基础上设计并实现了一套基于 B/S 架构的医疗器械专利自动分类系统以满足专利文本分类任务中批量处理和结果留存的需要^[55-62]。

本章主要介绍系统需求分析、系统架构设计、数据库设计、核心功能实现和系统测试验证。

5.1 需求分析

医疗器械专利分类系统的应用目标是将专利摘要文本映射到《医疗器械分类目录》的一级产品类别，并对分类结果进行保存、查询和导出。与单次模型预测不同，实际使用过程通常包含批量导入、结果复核、历史追踪和离线归档等环节。因此，系统需求既包括模型推理功能，也需要包括围绕分类结果展开的数据管理功能。

根据系统业务流程，本文将系统功能划分为用户模块、单条分类模块、批量分类模块、分类历史记录模块、结果导出模块和分类结果可视化模块。各模块共同构成从用户登录、文本提交、模型推理到结果管理的完整流程。

5.1.1 功能需求分析

（1）用户模块

用户模块用于完成系统访问控制和用户身份识别，主要包括用户注册、登录认证、密保问题查询、密保答案校验和密码重置等功能。用户登录成功后，后端生成包含用户标识和时间戳的 Token，前端将其保存到本地，并在后续请求中通过请求头携带^[63]。后端根据 Token 解析用户身份，并将分类记录与用户账号关联，从而支持历史记录的用户级隔离。

（2）单条分类模块

单条分类模块用于处理单篇专利摘要的即时分类需求。用户在前端页面输入

专利摘要后调用 Java 后端分类接口。Java 后端完成摘要内容校验后，将文本转发至 Python 推理服务，Python 服务加载已训练完成的模型进行预测，返回类别、类别索引、置信度以及类别的概率分布。Java 后端接收预测结果后，将其返回给前端展示，同时写入数据库。

（3）批量分类模块

实际专利分类工作中，用户往往需要一次处理多条专利摘要。为减少重复输入操作，系统增加批量分类功能，支持用户上传 Excel 文件。文件上传后，系统先解析列名和前若干行数据供用户确认摘要所在列。用户确认后，后端为本次批量任务生成唯一批次 ID，并逐条调用 Python 推理服务完成分类。当前系统将单次批量分类上限设置为 50 条，以控制请求耗时和模型推理资源占用。若单条记录处理失败，系统将失败原因记录到失败列表中，不影响同批次其他记录继续执行。

（4）分类历史记录模块

分类历史记录模块用于保存和查询用户历次分类结果，记录内容包括专利摘要、预测类别、类别索引、预测置信度、全部类别概率分布、来源类型、批次 ID 和分类时间。用户可按照预测类别、时间范围、来源类型、摘要关键字和批次 ID 进行筛选并可查看单条分类记录详情，批次 ID 用于关联同一次批量分类任务中的多条记录，便于后续集中复核。

（5）结果导出模块

系统提供 Excel 导出功能，用于支持分类结果的离线复核和归档。用户在历史记录页面设置筛选条件后，可导出符合条件的分类记录。导出字段包括序号、专利摘要、预测类别、置信度、来源类型、批次 ID 和分类时间。为避免空数据导出和大批量导出造成服务压力，后端在导出前检查记录数量；当记录为空或超过 200 条时，系统返回相应提示。

（6）分类结果可视化模块

系统不仅仅要给出一个预测结果，还要提供模型对于每个类别的置信度，在此基础上利用图表等可视化手段展示待测文本属于各个类别的概率，使用户能够更加清楚地了解模型预测情况，进而为人工复核提供辅助依据。

5.1.2 非功能性需求分析

非功能性需求用于约束系统运行质量，本文选取直接影响用户体验和结果可用性的核心指标进行说明，包括在线分类响应、批量处理、历史查询、结果导出、权限隔离和异常处理等内容，如表 5-1 所示。上述指标面向本课题原型系统和小规模业务验证场景，不作为高并发 Web 平台的吞吐能力要求。

表 5-1 系统非功能性需求

指标项	具体要求
单条分类响应	模型预加载后，单条分类接口 t95 响应时间不超过 3s
批量分类能力	单次批量分类不超过 50 条，任务应在 5min 内完成
历史查询与导出	常规筛选查询 t95 响应时间不超过 2s；单次导出不超过 200 条
用户数据隔离	历史记录、详情和导出接口均需校验 Token，用户只能访问本人记录
异常处理	Python 服务异常或任务失败时，系统应返回错误提示，批量任务不中断

表 5-1 列出了系统非功能性需求。本文未单独设置高并发吞吐指标，而是围绕用户完成分类任务时直接感知到的环节进行约束；其中，t95 表示 95% 请求的响应时间不超过给定阈值。

5.2 系统设计

5.2.1 系统架构设计

本系统采用前后端分离 B/S 框架，以便表现层与逻辑层分离，有利于系统开发、维护及发布等。由于深度学习推理任务对计算能力以及运行平台有较高要求^[67]，若直接嵌入 Java 后端，会增加依赖管理和部署维护的复杂度。

本文据此将系统划分为表现层、服务层、模型层和数据层四个部分，其中模型层与数据层位于后端支撑侧，共同服务于上层业务流程。系统整体结构如图 5-1 所示。

(1) 表现层

以 Vue.js 为基础开发单页应用^[55]，主要用于系统的页面显示以及用户的交互操作，在此部分使用 Axios 与后端服务器进行异步的数据请求，完成专利文本上

传以及分类的结果获取，同时也利用 ElementUI 对页面的展示方式以及样式进行了统一^[56]。




图 5-1 系统架构图

(2) 业务逻辑层

业务逻辑层包括 Java 服务以及 Python 推理服务，采用异构方式实现业务控制与算法计算分离。基于 Java Spring Boot 开发的服务是整个系统的中枢^[58]，连接展示层和数据持久化层。而基于 Python Flask 开发的小型推理服务只进行与模型相关的运算操作^[59]，该服务集成 PyTorch 深度学习库，用于加载已经训练好的 BERT-TextCNN 模型并对外暴露稳定高效在线推理 API 供外部使用来对专利文本进行分类预测。

(3) 数据与模型层

数据与模型层包括 MySQL 数据库和本地模型文件^[60]。MySQL 保存用户信息和分类记录；模型文件包括训练完成的 BERT-TextCNN 权重、配置文件和预训练语言模型相关资源。Python 服务启动后加载模型文件，并在后续请求中复用已加载模型。

5.2.2 数据库设计

系统数据库设计符合第三范式 3NF，系统数据库用于保存用户认证信息和分类记录信息，主要包含 user 用户表和 classification_record 分类记录表。一个用户可以对应多条分类记录，两张表之间通过用户 ID 建立关联。数据库 ER 图如图 5-2 所示。




图 5-2 数据库 ER 图

user 表用于保存用户账号、密码、密保问题和密保答案等信息，其字段设计如表 5-2 所示。

表 5-2 用户信息表

字段名称	数据类型	约束条件	字段说明
id	INT	PrimaryKey,AutoIncrement	用户唯一标识 ID
username	VARCHAR(50)	Unique,NotNull	登录用户名
password	VARCHAR(100)	NotNull	加密存储的登录密码
question	VARCHAR(200)	NotNull	密码找回安全问题
answer	VARCHAR(200)	NotNull	密码找回安全答案

classification_record 表用于保存分类输出结果，其字段设计如表 5-3 所示。该表通过 source 字段区分单条分类和批量分类，通过 batch_id 字段标识同一次批量任务，从而支持按来源和按批次查询。

表 5-3 分类记录表

字段名称	数据类型	约束条件	字段说明
id	BIGINT	PrimaryKey,AutoIncrement	记录唯一标识
user_id	INT	Index,NotNull	用户 ID，0 表示匿名用户
summary	TEXT	NotNull	输入的专利摘要文本
pred_label	VARCHAR(100)	NotNull	模型预测类别名称
pred_index	INT	NotNull	预测类别索引
pred_probability	DOUBLE	NotNull	预测置信度
top_categories	JSON	Nullable	22 类概率分布
source	VARCHAR(20)	NotNull	来源类型，single 或 batch
batch_id	VARCHAR(50)	Index,Nullable	批量分类批次 ID
create_time	DATETIME	Index,NotNull	分类时间

5.3 系统实现

5.3.1 开发环境及工具

系统的搭建与运行需要稳定且兼容的软硬件环境，为保证系统完整以及实验可复现性，本文使用较为成熟的开发工具和技术栈进行该项目开发。

表 5-4 开发环境及工具配置一览

类别	名称/版本	说明
操作系统	Windows 11 (x64)	基础运行平台
编程语言和运行时	JDK 1.8, Python 3.11.4, Node.js 18.15.0	多语言混合开发环境
深度学习环境	CUDA Toolkit 12.8.93, Torch 2.7.1	模型推理支持
开发工具	IntelliJ IDEA	集成开发环境
数据库	MySQL 5.7	关系型数据持久化存储
前端技术栈	Vue 2.6.14, Element UI 2.15.14, ECharts 5.6.0	用户交互、数据展示等
后端框架	Spring Boot 2.6.13, Flask 3.1.2	业务逻辑及模型支持

具体软硬件环境以及相关软件版本如表 5-4 所示。操作系统使用 Windows11

作为底层操作系统，开发语言采用 Java 与 Python 结合方式编写程序，在 JDK 1.8 和 Python 3.11.4 上实现运行时环境，在深度学习部分使用 CUDA Toolkit 12.8 和 Torch 2.7.1 提供计算能力。前端和后端均基于 Vue 全家桶、Spring Boot 以及 Flask 框架完成，而数据库使用成熟稳定的 MySQL 5.7。

5.3.2 用户模块实现

用户模块用于承担系统访问控制和身份认证功能，在其中负责用户的认证以及授权工作。用户模块基于 Spring Boot 开发实现，采用 RESTful 风格与前端通信，如图 5-3 所示，包括用户注册、登录认证和忘记密码三个部分。

(1) 用户注册

用户在前端注册页面填写用户名、密码及密保问题等相关内容之后，在前端以 POST 方式向 `/api/auth/register` 提交这些信息。而后端接收到来自前端的请求之后，首先使用 `UserService` 判断该用户名是否已经被占用。如果用户名可以被使用，则使用 `BeanUtils` 将请求中的对象转换成相应的实体类的对象并将用户的信息保存到 MySQL 数据库中完成注册操作，同时也会生成一个 Token 返回给前端使得用户能够实现注册后自动登录。



图 5-3 用户模块功能界面

(2) 登录认证

登录操作利用 `/api/auth/login` 接口来完成，当用户向服务器发送用户名及密码时，服务器会在数据库里查找是否有此账户信息，如果找到，则说明这个用户存在，后端生成唯一 Token 并返回前端，这个 Token 是包含用户 id 以及当前时间

戳的信息，然后放在响应体里面返回到前端，前端拿到这个 Token 之后就保存到本地并在所有 API 请求头里带上这个 Token 作为自己的标识符，从而达到无状态会话的目的。

(3) 密码找回

当用户忘记密码时，本文提供一种基于密保问题的两步验证，既考虑了安全性也方便使用。第一步就是认证，也就是让用户输入用户名以及保存答案，再由服务器在/api/auth/verify-security-question 接口判断是否正确。第二步就是重设新密码，在认证成功之后，用户可以调用/api/auth/reset-password 接口修改自己的密码。该流程可降低非授权密码重置风险，并为用户提供账号恢复途径。

5.3.3 单条分类模块实现

单条分类模块通过/api/patent/classify 接口实现。前端提交摘要后，Java 后端先判断摘要是否为空，再从 Token 中解析用户 ID，并将摘要封装为 JSON 请求发送至 Python 推理服务的/predict 接口。

Python 推理服务接收到文本后，使用 BERT 分词器进行编码，得到模型所需的 input_ids 和 attention_mask。随后，服务端将张量输入 BERT-TextCNN 模型，得到 22 维 logits，并通过 Softmax 转换为概率分布。概率最高的类别作为预测类别返回。Java 后端收到结果后，将摘要、预测类别、类别索引、置信度、全部类别概率分布和来源类型写入 classification_record 表；单条分类记录的 source 字段取值为 single。



图 5-4 单条分类界面

前端接收结果后展示预测类别、置信度和概率分布图，使用户既能获得最终分类标签，也能查看模型对其他类别的概率判断。

5.3.4 批量分类模块实现

批量分类模块由/api/patent/upload-preview 和/api/patent/batch-classify 两个接口配合完成，前者负责文件预览，后者负责执行批量分类。

用户上传 Excel 文件后，前端将文件发送至/api/patent/upload-preview。后端检查文件是否为空，并判断文件格式是否符合批量导入要求，校验通过后，系统使用 EasyExcel 解析表头和数据行，返回列名列表、总行数以及前 5 行预览数据。用户据此选择摘要所在列。

用户确认摘要列后，前端将文件和列名提交至/api/patent/batch-classify，后端重新解析文件，检查摘要列是否存在，同时判断记录数是否超过 50 条，通过校验后，系统生成 UUID 作为本次任务的 batch_id，再逐条读取摘要并调用 Python 推理服务。逐条调用策略能够降低模型服务瞬时压力，并便于记录单条失败原因。

分类成功的记录被封装为 ClassificationRecord 对象，其中 source 设置为 batch，batch_id 设置为本次任务 ID，批量任务结束后，系统将成功记录写入数据库，并向前端返回批次 ID、总数、成功数、失败数、成功结果列表和失败列表。用户后续可在历史页面通过批次 ID 查询本次任务的全部结果。



图 5-5 批量分类功能界面

5.3.5 分类历史与导出模块实现

分类历史模块通过/api/record/list 和/api/record/{id}接口实现。列表接口支持预测类别、开始时间、结束时间、来源类型、摘要关键字和批次 ID 等筛选条件，后端解析 Token 得到用户 ID，并将其作为隐式查询条件，保证用户只能查询本人分类记录。

详情接口返回单条记录的完整摘要和全部类别概率分布。前端在详情弹窗中复用概率图组件，使在线分类结果和历史记录详情保持一致的展示方式。

导出模块通过/api/record/export 接口实现。用户设置筛选条件后点击导出，后端先统计符合条件的记录数量。数量为 0 时，系统返回“暂无数据”；超过 200 条时，提示用户缩小筛选范围；数量符合要求时，系统查询记录并使用 EasyExcel 生成 Excel 文件^[64]，以响应流形式返回前端。导出内容可用于离线复核和阶段性结果归档。



图 5-6 分类历史与结果导出功能界面

5.4 系统测试与验证

系统开发完成后，需要通过测试验证其功能完整性和运行稳定性。本文从功能测试和非功能测试两个角度进行验证，测试范围覆盖用户认证、单条分类、批量分类、历史记录、筛选查询和结果导出等主要流程。

5.4.1 功能测试

功能测试用例如表 5-5 所示。为避免测试表过长，本文选取能够覆盖主要业务闭环的核心用例进行列示，包括用户认证、单条分类、批量分类、历史查询、详情查看和结果导出等功能。测试结果显示，系统能够覆盖单条分类、批量处理和结果管理等核心需求。

表 5-5 系统功能测试用例

用例编号	测试功能	输入或操作	预期结果
TC-001	用户认证	注册并使用正确账号登录	注册成功，登录后返回 Token
TC-002	密码找回	输入正确密保答案设置新密码	密码重置成功
TC-003	单条分类	输入有效专利摘要	返回预测类别、置信度和概率分布
TC-004	输入校验	空摘要或不符合要求的文件	返回明确错误提示
TC-005	批量分类	上传包含摘要列且不超过 50 条的 Excel 文件	返回批次 ID、成功数和失败数
TC-006	历史查询	按类别、时间、来源、关键字或批次 ID 筛选	返回符合条件的分类记录
TC-007	记录详情	点击历史记录详情	展示完整摘要和 22 类概率分布
TC-008	结果导出	对筛选结果执行 Excel 导出	200 条以内可导出，超出上限时提示缩小范围

5.4.2 非功能测试

非功能测试主要依据表 5-1 中提出的核心指标进行验证，结果见表 5-6。由于不同运行设备、模型加载状态和输入文本长度都会影响响应耗时，本文采用接口调用和页面操作相结合的方式进行测试，重点验证用户主要操作能否在设定边界内完成。

功能测试与非功能测试结果表明，系统主要业务流程能够按预期执行，运行状态基本稳定，能够满足原型系统的功能验证和应用测试要求。

表 5-6 系统非功能测试结果

测试项	验收要求	测试结果
单条分类响应	t95 响应时间不超过 3s	模型服务预加载后，连续提交测试摘要，响应时间满足要求
批量分类能力	50 条以内任务在 5min 内完成	系统能够返回批次 ID、成功数和失败数
历史查询与导出	查询 t95 不超过 2s，导出不超过 200 条	筛选查询正常返回，200 条以内数据可导出
用户数据隔离	未登录请求被拒绝，用户不能访问他人记录	历史记录、详情和导出接口均按用户 ID 过滤
异常处理	下游异常或单条失败不导致批量任务整体中断	异常记录进入失败列表，前端能够获得错误提示

第六章 总结与展望

6.1 总结

本文围绕医疗器械发明专利与《医疗器械分类目录》之间的自动映射问题展开研究。现有专利分类体系主要面向技术主题组织，而医疗器械监管分类体系更强调产品用途、风险属性和监管归属，两者在分类逻辑上存在差异。与此同时，真实专利数据中的原始标签存在噪声，医疗器械专利文本又具有术语密集、类别边界交叉和长尾类别明显等特点，直接制约了分类模型的训练效果和应用可靠性。针对上述问题，本文围绕数据质量控制、跨体系分类建模以及模型验证与应用三个环节开展研究，重点解决弱标签条件下训练数据构建、专利技术文本向监管目录类别映射以及模型实际应用效果验证等问题。

（1）构建了面向弱标签条件的医疗器械专利数据治理流程

本文以主要 IPC 分类号属于 A61B 且申请日期不晚于 2023 年 12 月 31 日的发明专利作为候选数据来源，并结合授权状态、附图、一级产品类别标签和文本完整性等条件进行筛选。为避免重复样本影响模型训练，本文以申请号作为唯一标识进行去重，最终获得 58495 条原始候选数据。在此基础上，本文抽取 1104 条样本构建专家校对数据集 D2，并通过二级类别预测、分层抽样和 JS 散度评估尽量保持抽样子集与原始数据分布的一致性。

（2）构建了引入分类目录知识和规则校验的自动标注流程

针对原始标签存在噪声和人工标注成本较高的问题，本文基于 Qwen 大模型、Dify 工作流、《医疗器械分类目录》和《医疗器械分类规则》构建自动标注流程。该流程在模型判断过程中引入分类目录条目、医疗器械分类规则和易混类别区分依据，并针对医用成像器械、无源植入器械、无源手术器械、医用软件等易混类别设置二次校验环节。实验结果显示，完整结构在 D2 上的 Accuracy 为 0.9321，Macro F1-score 为 0.9220，优于原始标签、关键词匹配和 KNN+BGE 等方法。消融实验也表明，分类规则、分类目录知识和纠错分支均对标注质量提升具有作用。

（3）形成了从案例分析、置信度过滤到增强质量控制的数据质量闭环

本文没有直接将自动标注结果作为训练数据，而是以专家校对数据集 D2 为

评价基准,先对不同自动标注方法进行对比,再通过案例分析说明分类目录知识和纠错分支对易混类别的修正作用。案例分析中既保留了修正成功的样本,也保留了因摘要关键信息占比过低而导致失败的边界样本,用于说明方法的适用范围。随后,本文利用原始标签与自动标注标签的一致性划分高低置信层,并通过 D3 抽样验证和 TOST 等价性检验确认高置信样本的可用性。对于低置信样本,本文选择剔除而非直接纠错,这是在专家校对成本和训练数据质量之间作出的权衡。

在置信度过滤后,本文得到 34431 条高质量标注数据。针对训练中难以学习的极少数类别,本文没有对所有少数类统一增强,而是依据训练过程中的可学习性,仅对“输血、透析和体外循环器械”进行定向增强。增强文本进入训练集前经过人工核验,并结合语义相似度分析检查生成摘要与来源专利之间的语义一致性。最终,本文将 34431 条过滤后数据与 62 条增强样本合并,形成 34493 条训练数据。

(4) 完成了医疗器械专利一级产品类别分类模型的设计与评估

本文以《医疗器械分类目录》22 个一级产品类别为分类目标,构建并评估 BERT-TextCNN 分类模型。需要说明的是,BERT-TextCNN 并非本文提出的全新神经网络结构,本文的重点在于将预训练语言模型的全局语义表示与 TextCNN 的局部短语特征提取能力应用于医疗器械专利分类任务,并结合本文构建的数据集进行任务适配和实验验证。模型对比实验显示,BERT-TextCNN 在测试集上的 Accuracy 为 0.9261,Macro F1-score 为 0.8792,Weighted F1-score 为 0.9249,优于 KNN、DeepPatent、PatentSBERTa、PaECTER 和 RAMHA 等对比方法。消融实验表明,微调策略、TextCNN 局部特征通路和定向数据增强均对模型性能具有贡献,其中定向数据增强主要改善了极少数类别的识别效果。

(5) 通过外部验证和系统实现检验了方法的应用可行性

为考察模型在新时间段数据上的适应能力,本文构建了 330 条来自医知桥平台 2025 年发明专利的外部验证集,并由专家进行复核标注。实验结果显示,BERT-TextCNN 在外部验证集上的 Accuracy 为 0.8424,Macro F1-score 为 0.8546,Weighted F1-score 为 0.8428,高于医知桥平台对应结果。该实验说明本文模型在跨时间数据上具有一定适应能力,但由于外部验证集规模和来源仍有限,其结果更适合作为应用可行性的初步验证,而不能等同于对全部产业场景的充分证明。

在模型研究基础上，本文进一步设计并实现了医疗器械专利自动分类系统。系统采用 Vue 前端、Spring Boot 后端、Flask 推理服务和 MySQL 数据库组成的异构架构，支持用户认证、单条分类、批量上传、批量分类、历史查询、条件筛选、结果导出和概率可视化等功能。与仅提供单条分类的原型相比，修改后的系统更接近实际专利分类业务中批量处理、结果留存和离线复核的使用需求。

6.2 创新点

本文针对医疗器械专利分类所面临的问题进行改进，主要包括以下几个方面的内容：

（1）构建了面向弱标签条件的医疗器械专利数据治理流程

针对医疗器械专利缺少公开高质量标注数据的问题，本文没有直接使用原始标签，而是通过专家校对数据集、自动标注方法对比、案例分析、双信号一致性分析、抽样验证和 TOST 等价性检验逐步筛选训练数据。该流程将专家校对、自动标注和统计检验结合起来，为弱标签条件下构建医疗器械专利分类数据集提供了一种可复查的实现路径。

（2）设计了引入医疗器械分类知识的自动标注 workflow

本文在自动标注阶段引入《医疗器械分类目录》和《医疗器械分类规则》等外部知识，并通过目录检索和条件纠错分支处理易混类别。与单纯依赖 LLM 生成标签不同，该 workflow 将分类目录知识、规则提示和错误纠正机制嵌入标注流程，使自动标注结果具有更强的领域约束。对比实验和消融实验表明，该设计能够提升医疗器械一级产品类别标注质量。

（3）实现专利分类体系到医疗器械分类目录之间跨体系匹配及应用落地

本文不同于仅在 IPC 或 CPC 体系内部开展类别细分的专利分类研究，而是面向医疗器械专利文本与《医疗器械分类目录》之间的跨体系映射任务，建立了从专利技术描述到监管目录类别的自动分类路径。在此基础上，本文借助 B/S 架构实现在线专利自动分类工具，验证了模型在批量分类、历史留存和结果导出等实际流程中的接入方式。该系统目前仍属于原型系统，其价值主要体现在应用验证层面，可为后续医疗器械垂直领域专利分类数据平台建设提供参考。

6.3 展望

尽管本文围绕医疗器械发明专利自动分类完成了数据质量控制、分类模型构建和应用验证，但受数据来源、标注成本、实验条件和研究周期限制，仍有若干问题需要在后续工作中进一步完善。

（1）进一步开展二级、三级目录的层次化分类研究

本文当前聚焦《医疗器械分类目录》中的 22 个一级产品类别，并非忽略目录本身的层级结构，而是在原始数据缺少稳定二级、三级标签的条件下，先建立专利文本向监管目录的第一层级映射基准。若直接开展二级、三级分类，部分类别样本不足会放大监督信号噪声，影响模型评估的可靠性。因此，后续研究可在一级分类结果稳定后，引入层次化文本分类模型或路径约束机制，使模型在预测细粒度类别时保持上下级目录之间的逻辑一致性^[65]。同时，还需要解决二级、三级类别样本稀疏和类间边界更细的问题。

（2）扩大专家校对规模

本文构建了 1104 条专家校对数据集 D2，并进一步对 D3 高低置信层进行抽样验证。该设计能够在有限人工成本下评估自动标注结果和置信度过滤策略，但专家校对规模仍然有限，尚不能完全覆盖所有类别边界和复杂样本形态。后续研究可扩大专家校对样本规模，特别是增加低置信样本和模型预测不确定样本的人工复核比例^[66-68]。

（3）完善低置信样本的纠错与再利用机制

本文为保证训练标签质量，最终只保留通过验证的高置信样本，并剔除了低置信样本。这样的处理能够降低噪声标签对模型训练的影响，但也可能使训练数据更偏向于类别边界相对清晰的样本。受专家校对成本限制，本文尚未对上万条低置信样本逐条纠错，这是本研究的重要局限。

后续工作可引入主动学习策略，优先选择模型不确定性高、原始标签与自动标注标签冲突的样本进行专家复核^[69]；也可以结合规则校验、相似案例检索和多轮人工复查，对低置信样本进行分批纠错^[70]。在此基础上，可将纠错后的低置信样本重新纳入训练集，进一步检验模型在复杂边界样本上的表现。

（4）多模态数据融合

本文主要是根据专利摘要来进行分类工作，在实际中，专利文件中的图片包

含大量的形状以及结构上的内容，这对功能相近但结构不同设备的区分具有参考价值，后续可考虑引入图像处理方法对专利附图进行特征提取，利用多模态的方法融合文本以及图片的信息，提高分类效果^[71]。

（5）数据范围的扩展

本文仅选取 IPC 分类号为 A61B 的中文发明专利作为研究对象，后续工作可以进一步扩大研究范围到其他相关 IPC 小类，以便更加充分地包含可能涉及医疗器械技术的发明专利。虽然部分 IPC 小类并不直接标注为医疗器械，但其涉及的技术内容仍可能与医疗器械存在较高关联。

另外，后续工作还可以加入英文专利文献，在已有工作的基础上开展跨语言、跨领域医疗器械专利自动分类研究。专利文本具有较强的技术性、法律性和结构化表达特征，相关综述研究也表明，专利领域 NLP 仍然需要结合专利文本特点进行任务适配^[72]。因此，扩大数据来源和语言范围有助于进一步提升分类器的适用范围和稳健性。

（6）模型的可解释性研究

当前的 BERT-TextCNN 模型虽然具有较高的分类准确率，但是仍然存在一定程度的“黑盒”问题^[73,74]。而在医疗器械监管以及专利审查的工作环境中，审核人员除了关心分类的结果外，还需要知道模型是如何得出这个结论的^[74]，比如为什么该发明会被认为是“有源手术器械”，而不是“无源手术器械”。加强模型透明度可以提高监管部门对于自动化的接受程度，也可以帮助找到一些问题所在从而改进模型。

参考文献

- [1] 邢文中.我国创新医疗器械产业发展布局与思考[J].中国医疗器械信息,2022,28(23):1-3.DOI:10.15971/j.cnki.cmdi.2022.23.053.
- [2] TOPOL E J. High-performance medicine: the convergence of human and artificial intelligence[J]. Nature Medicine, 2019, 25(1): 44-56.
- [3] 国务院办公厅. 关于发展银发经济增进老年人福祉的意见: 国办发〔2024〕1号[EB/OL]. (2024-01-15) [2026-03-16].
https://www.gov.cn/zhengce/zhengceku/202401/content_6926088.htm.
- [4] 冯晓青. 企业知识产权战略[M]. 3版. 北京: 知识产权出版社, 2008: 156-180.
- [5] European Patent Office. Patent Index 2024: Statistics and trends in medical technology[R]. Munich: EPO, 2025.
- [6] 2024年度医疗器械注册工作报告[EB/OL]. [2026-03-16].
<https://www.nmpa.gov.cn/xxgk/fgwj/gzwj/gzwjylqx/20250213095700131.html>.
- [7] Locarno Agreement Establishing an International Classification for Industrial Designs[EB/OL]. [2026-03-17].
<https://www.wipo.int/en/web/treaties/classification/locarno/index>.
- [8] CPC Definition - G16H HEALTHCARE INFORMATICS, i.e. INFORMATION AND COMMUNICATION TECHNOLOGY [ICT]...[EB/OL]. [2026-03-16].
<https://www.uspto.gov/web/patents/classification/cpc/html/defG16H.html>.
- [9] 医疗器械分类目录[EB/OL]. [2026-03-16].
<https://baike.baidu.hk/item/%E5%8C%BB%E7%96%97%E5%99%A8%E6%A2%B0%E5%88%86%E7%B1%BB%E7%9B%AE%E5%BD%95/9893267>.
- [10] NMPA Classification Specifications - China Med Device[EB/OL]. [2026-03-16].
<https://chinameddevice.com/services/regulatory-services/ra-strategy/nmpa-classification/>.
- [11] SHIMANUKI S, SAIKI T. Technological diversity management of medical device enterprises[J]. Journal of Strategy and Management, 2012, 5(4): 420-436.
- [12] XIE X, WU J, XIANG M, et al. Enhancing the efficiency of patent classification: a multimodal classification approach for design patents[J]. Journal of King Saud University Computer and Information Sciences, 2025, 37(7): 183.
- [13] PUJARI S C, MANTIUK F, GIERETH M, et al. Evaluating neural multi-field document representations for patent classification[C]//FROMMHOLZ I, MAYR P, CABANAC G, et al. BIR 2022: Proceedings of the 12th International Workshop on Bibliometric-enhanced Information Retrieval. Aachen: CEUR-WS, 2022: 13-27[2026-05-07].
<https://ceur-ws.org/Vol-3230/paper-04.pdf>.
- [14] LIU Z, LIU L. Patent protection of biological genetic resources based on deep learning and artificial intelligence[J]. Scientific Reports, 2025, 15(1): 41302.
- [15] HARRIS Z S. Distributional structure[J]. Word, 1954, 10(2/3): 146-162.
DOI:10.1080/00437956.1954.11659520.
- [16] SALTON G, BUCKLEY C. Term-weighting approaches in automatic text retrieval[J]. Information Processing & Management, 1988, 24(5): 513-523.

- DOI:10.1016/0306-4573(88)90021-0.
- [17] CAVNAR W B, TRENKLE J M. N-gram-based text categorization[C]//Proceedings of the 3rd Annual Symposium on Document Analysis and Information Retrieval. Las Vegas: University of Nevada, 1994: 161-169.
 - [18] KIM Y. Convolutional neural networks for sentence classification[C]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. Doha: Association for Computational Linguistics, 2014: 1746-1751.
 - [19] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. *Neural Computation*, 1997, 9(8): 1735-1780. DOI:10.1162/neco.1997.9.8.1735.
 - [20] DEVLIN J, CHANG M W, LEE K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Minneapolis: Association for Computational Linguistics, 2019: 4171-4186. DOI:10.18653/v1/N19-1423.
 - [21] BELTAGY I, PETERS M E, COHAN A. Longformer: The long-document transformer[EB/OL]. arXiv, 2020[2026-05-07]. <https://arxiv.org/abs/2004.05150>.
 - [22] YANG Z, YANG D, DYER C, et al. Hierarchical attention networks for document classification[C]//Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. San Diego: Association for Computational Linguistics, 2016: 1480-1489. DOI:10.18653/v1/N16-1174.
 - [23] BAI J, BAI S, CHU Y, et al. Qwen technical report[EB/OL]. arXiv, 2023[2026-05-07]. <https://arxiv.org/abs/2309.16609>.
 - [24] BAI Y, LV X, ZHANG J, et al. LongAlign: A recipe for long context alignment of large language models[EB/OL]. arXiv, 2024[2026-05-07]. <https://arxiv.org/abs/2401.18058>.
 - [25] CHEN S, WONG S, CHEN L, et al. Extending context window of large language models via positional interpolation[EB/OL]. arXiv, 2023[2026-05-07]. <https://arxiv.org/abs/2306.15595>.
 - [26] LEE J S, HSIANG J. PatentBERT: Patent Classification with Fine-Tuning a pre-trained BERT Model[EB/OL]. arXiv, 2019[2026-03-17]. <http://arxiv.org/abs/1906.02124>.
 - [27] BEKAMIRI H, HAIN D S, JUROWETZKI R. PatentSBERTa: A Deep NLP based Hybrid Model for Patent Distance and Classification using Augmented SBERT[EB/OL]. arXiv, 2021[2026-03-17]. <http://arxiv.org/abs/2103.11933>.
 - [28] LIU Y, OTT M, GOYAL N, et al. RoBERTa: A Robustly Optimized BERT Pretraining Approach[EB/OL]. arXiv, 2019[2026-03-17]. <http://arxiv.org/abs/1907.11692>.
 - [29] YANG Z, DAI Z, YANG Y, et al. XLNet: Generalized Autoregressive Pretraining for Language Understanding[C/OL]//Advances in Neural Information Processing Systems: Vol. 32. Curran Associates, Inc., 2019[2026-03-17]. https://proceedings.neurips.cc/paper_files/paper/2019/hash/dc6a7e655d7e5840e66733e9ee67cc69-Abstract.html.
 - [30] ZHU H, ZHANG C, HUANG J, et al. HiTIN: Hierarchy-aware Tree Isomorphism Network for Hierarchical Text Classification[C/OL]//ROGERS A, BOYD-GRABER J, OKAZAKI N. Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Toronto, Canada: Association for Computational Linguistics, 2023: 7809-7821[2026-03-17]. <https://aclanthology.org/2023.acl-long.432/>.
 - [31] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-Augmented Generation for

- Knowledge-Intensive NLP Tasks[EB/OL]. arXiv, 2021[2026-03-17].
<http://arxiv.org/abs/2005.11401>.
- [32] langgenius/dify[CP/OL]. LangGenius, 2026[2026-03-17]. <https://github.com/langgenius/dify>.
- [33] GHOSH M, ERHARDT S, ROSE M E, et al. PaECTER: Patent-level representation learning using citation-informed transformers[EB/OL]. arXiv, 2024[2026-05-07].
<https://arxiv.org/abs/2402.19411>.
- [34] KUMAR M, KHAN L, CHOI A. RAMHA: A hybrid social text-based transformer with adapter for mental health emotion classification[J]. Mathematics, 2025, 13(18): 2918.
DOI:10.3390/math13182918.
- [35] 智慧芽官网: 更懂技术创新的 AI Agent 平台[EB/OL]. [2026-05-07].
<https://www.zhihuiya.com/>.
- [36] 医知桥[EB/OL]. [2026-03-17]. <https://www.mediaplank.com.cn/login>.
- [37] 国家食品药品监督管理总局. 关于发布《医疗器械分类目录》动态调整工作程序的公告 (2021 年第 60 号) [EB/OL]. (2021-04-27). <https://www.nmpa.gov.cn>.
- [38] 国家食品药品监督管理总局. 关于发布医疗器械分类目录的公告: 2017 年第 104 号 [EB/OL]. (2017-08-31)[2026-05-06].
<https://www.nmpa.gov.cn/xxgk/ggtg/ylqxggtg/ylqxqgtggtg/20170904150301406.html>.
- [39] Northcutt C G, Jiang L, Chuang I L. Confident Learning: Estimating Uncertainty in Dataset Labels[J]. Journal of Artificial Intelligence Research, 2021, 70: 1373-1411. DOI: 10.1613/jair.1.12125 .
- [40] Gilardi F, Alizadeh M, Kubli M. ChatGPT out-performs crowd-workers for text-annotation tasks[J]. Proceedings of the National Academy of Sciences (PNAS), 2023, 120(28): e2305016120. DOI: 10.1073/pnas.2305016120.
- [41] SCHUIRMANN D J. A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability[J]. Journal of Pharmacokinetics and Biopharmaceutics, 1987, 15(6): 657-680. DOI: 10.1007/BF01068419.
- [42] COX D R. The Regression Analysis of Binary Sequences[J]. Journal of the Royal Statistical Society: Series B (Methodological), 1958, 20(2): 215-242.
- [43] COVER T, HART P. Nearest neighbor pattern classification[J]. IEEE Transactions on Information Theory, 1967, 13(1): 21-27.
- [44] BREIMAN L. Random Forests[J]. Machine Learning, 2001, 45(1): 5-32.
- [45] CHEN T, GUESTRIN C. XGBoost: A scalable tree boosting system[C]//Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Francisco: ACM, 2016: 785-794.
- [46] google-bert/bert-base-chinese · Hugging Face[EB/OL]. (2018-10-11)[2026-03-17].
<https://huggingface.co/google-bert/bert-base-chinese>.
- [47] hfl/chinese-roberta-wwm-ext · Hugging Face[EB/OL]. (2024-05-07)[2026-03-17].
<https://huggingface.co/hfl/chinese-roberta-wwm-ext>.
- [48] hfl/chinese-macbert-base · Hugging Face[EB/OL]. (2024-05-07)[2026-03-17].
<https://huggingface.co/hfl/chinese-macbert-base>.
- [49] CUI Y, CHE W, LIU T, et al. Pre-training with Whole Word Masking for Chinese BERT[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2021, 29: 3504-3514. DOI: 10.1109/TASLP.2021.3124368.
- [50] WANG Z, WANG P, HUANG L, et al. Incorporating hierarchy into text encoder: a

- contrastive learning approach for hierarchical text classification[C]//Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Dublin: Association for Computational Linguistics, 2022: 7109-7119. DOI: 10.18653/v1/2022.acl-long.491.
- [51] BAAI/bge-large-zh-v1.5 · Hugging Face[EB/OL]. (2026-02-04)[2026-03-17]. <https://huggingface.co/BAAI/bge-large-zh-v1.5>.
- [52] ollama/ollama[CP/OL]. Ollama, 2026[2026-03-17]. <https://github.com/ollama/ollama>.
- [53] Docker: lightweight Linux containers for consistent development and deployment: Linux Journal: Vol 2014, No 239[EB/OL]. [2026-03-17]. <https://dl.acm.org/doi/10.5555/2600239.2600241>.
- [54] Li S, Hu J, Cui Y, et al. DeepPatent: patent classification with convolutional neural networks and word embedding[J]. Scientometrics, 2018, 117(2): 721-744.
- [55] VUE.JS. Introduction — Vue.js[EB/OL]. [2026-03-17]. <https://v2.vuejs.org/v2/guide/>.
- [56] ELEMENT. Element - The world's most popular Vue UI framework[EB/OL]. [2026-03-17]. <https://element.eleme.io/>.
- [57] APACHE ECHARTS. Apache ECharts Handbook[EB/OL]. [2026-03-17]. <https://echarts.apache.org/handbook/en/get-started/>.
- [58] SPRING. Spring Boot Reference Documentation 2.6.13[EB/OL]. [2026-03-17]. <https://docs.spring.io/spring-boot/docs/2.6.13/reference/html/>.
- [59] PALLET. Flask Documentation[EB/OL]. [2026-03-17]. <https://flask.palletsprojects.com/>.
- [60] ORACLE. MySQL 5.7 Reference Manual[EB/OL]. [2026-03-17]. <https://dev.mysql.com/doc/refman/5.7/en/>.
- [61] ELEMENT. Element UI Documentation[EB/OL]. [2026-03-17]. <https://element.eleme.io/>.
- [62] APACHE ECHARTS. Documentation - Apache ECharts[EB/OL]. [2026-03-17]. <https://echarts.apache.org/en/index.html>.
- [63] JONES M, HARDT D. The OAuth 2.0 Authorization Framework: Bearer Token Usage: RFC 6750[S/OL]. 2012[2026-05-07]. <https://www.rfc-editor.org/rfc/rfc6750>.
- [64] ALIBABA. EasyExcel: 快速、简洁、解决大文件内存溢出的 Java 处理 Excel 工具[CP/OL]. [2026-03-17]. <https://github.com/alibaba/easyexcel>.
- [65] SOERGEL D, LAUSER B, LIANG A, et al. Automated patent categorization and guided patent search using IPC as inspired by MeSH and PubMed[J/OL]. Journal of Biomedical Semantics, 2013, 4(Suppl 1): S3[2026-03-17]. <https://doi.org/10.1186/2041-1480-4-S1-S3>.
- [66] COHEN J. A coefficient of agreement for nominal scales[J]. Educational and Psychological Measurement, 1960, 20(1): 37-46. DOI: 10.1177/001316446002000104.
- [67] SZE V, CHEN Y H, YANG T J, et al. Efficient Processing of Deep Neural Networks: A Tutorial and Survey[J]. Proceedings of the IEEE, 2017, 105(12): 2295-2329. DOI:10.1109/JPROC.2017.2761740.
- [68] ARTSTEIN R, POESIO M. Inter-coder agreement for computational linguistics[J]. Computational Linguistics, 2008, 34(4): 555-596. DOI: 10.1162/coli.07-034-R2.
- [69] SETTLES B. Active learning literature survey[R/OL]. Madison: University of Wisconsin-Madison, 2009[2026-03-17]. https://burrsettles.com/pub/settles.activelearning_20090109.pdf.
- [70] ZHANG J, REN H, GUO S, et al. Multi-model collaboration and prompt-driven patent classification methods[C/OL]//Proceedings of the 2024 4th International Conference on

- Artificial Intelligence, Big Data and Algorithms. New York: Association for Computing Machinery, 2024: 332-336[2026-03-16]. <https://dl.acm.org/doi/10.1145/3690407.3690464>.
- [71] BALTRUŠAITIS T, AHUJA C, MORENCY L P. Multimodal machine learning: a survey and taxonomy[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2019, 41(2): 423-443. DOI: 10.1109/TPAMI.2018.2798607.
- [72] JIANG L, GOETZ S M. Natural language processing in the patent domain: a survey[J]. Artificial Intelligence Review, 2025, 58(7): 214. DOI: 10.1007/s10462-025-11168-z.
- [73] SZCZEPAŃSKI M, PAWLICKI M, KOZIK R, et al. New explainability method for BERT-based model in fake news detection[J]. Scientific Reports, 2021, 11(1): 23705. DOI: 10.1038/s41598-021-03100-6.
- [74] ZHANG X, LIU S. Explainable judgment prediction and article-violation analysis using deep LexFaith hierarchical BERT model[J]. Scientific Reports, 2026, 16(1): 2974. DOI: 10.1038/s41598-025-32833-x.

致谢

随着这篇硕士论文完成，我的学习生活也要告一段落，在这期间有苦有乐，从最初的迷茫到不断地改进自己的方案，每一点进步都离不开我的指导老师、师兄师姐以及家人的关心帮助。

首先，我想对我导师**教授表示由衷地感激之情，在论文初稿撰写、模型设计、代码调试以及最后定稿过程中都得到**老师的悉心指导，在此谨向**老师表示衷心感谢。是**老师认真负责的工作态度，扎实渊博学识以及对待每一个环节一丝不苟精神让我明白什么是真正的学者风范并学会如何做一个学者。其次，我还需要对指导我平时学习生活、工作中遇到问题时提供帮助和指导的**副教授表示诚挚谢意。两位老师对我指导和帮助使我在学术之路上更加坚定信心。

再次，感谢一路上陪伴我的各位同门，在实验室一起研究学习，也曾在科研之外参与各种各样的事务，在相互鼓励之间激发思想，在日常生活当中建立友情的美好时光，给这段困难重重的学习生涯带来很多快乐，也是我研究生生涯中最珍贵、最耀眼的回忆。

另外，我也要特别感谢远在中原的亲人们。你们或许并不了解我每天接触的各种各样的算法以及数据，但是你们对我的关心、理解和全力支持，都是我学习生活中最重要的依靠，是你们的无私奉献让我能够专心致志投入到我的学业中去写成这篇论文。

最后，向所有参加本论文评阅、答辩的各位老师表示衷心感谢，在百忙之中对我论文审阅并提出许多有益建议。

凡是过往，皆为序章。带着这份感谢和期盼，我将迎接人生新的旅程。祝愿各位老师身体健康，工作顺利，祝愿各位同学前程似锦，万事顺遂！